

数据可视化

第二章 可视化图表

上官武悦

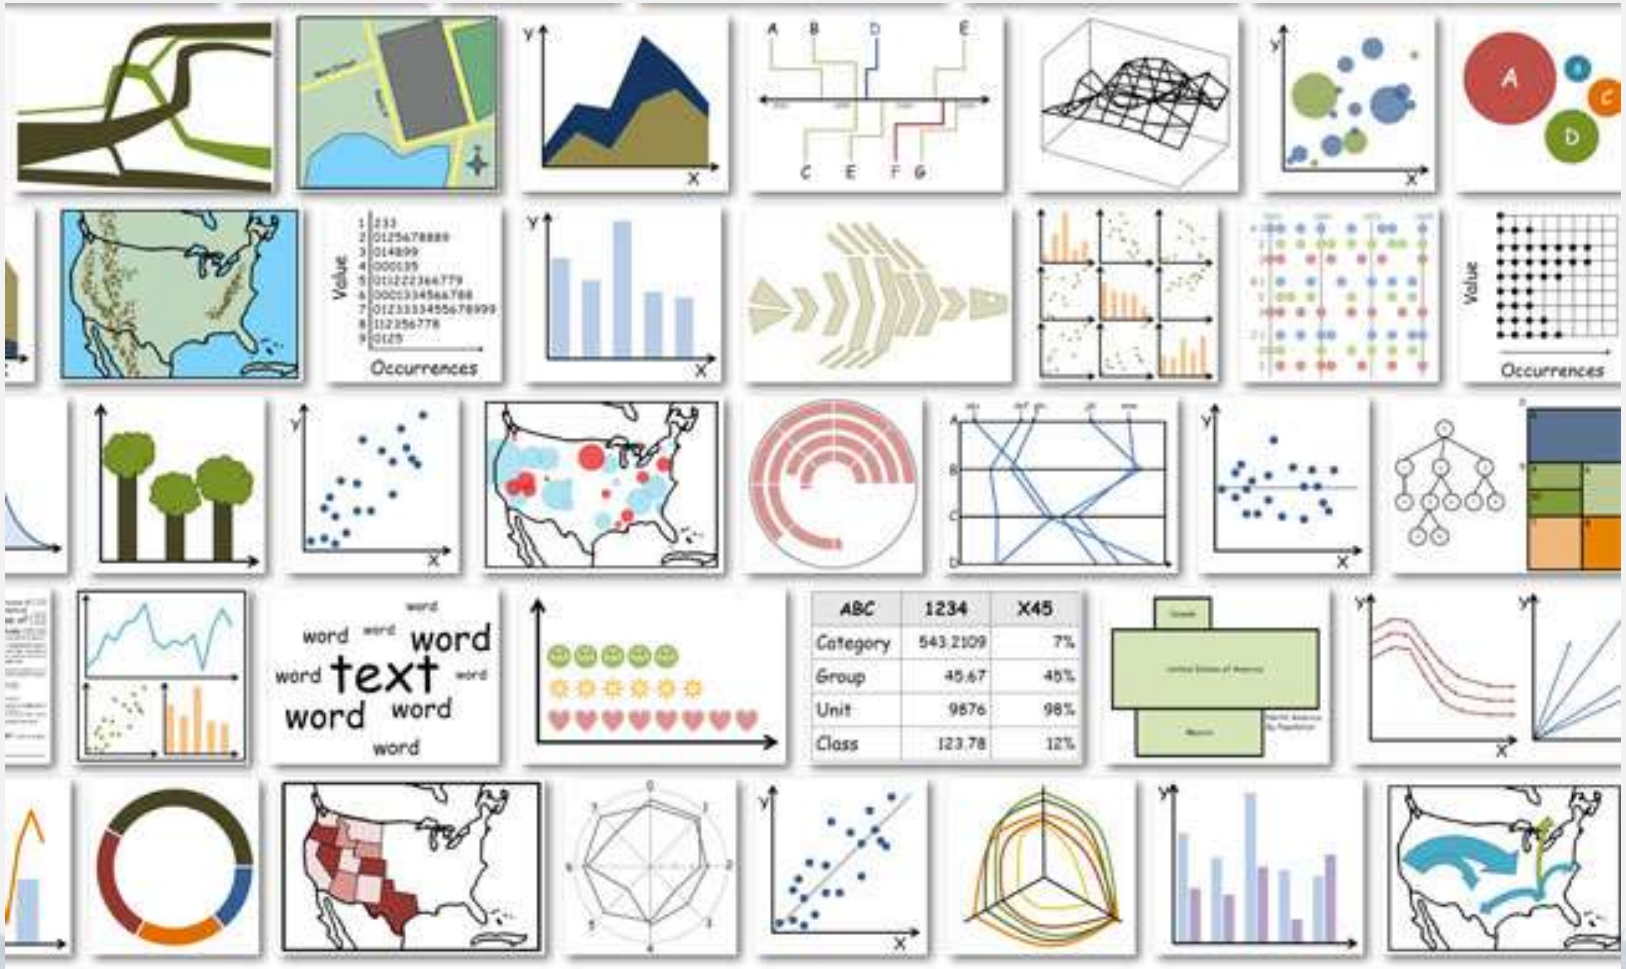
2026年9月17日

本章内容

- 可视化图表的类型
  - 基本统计图表
  - 专题地图
  - 网络和树形可视化
  - 文本可视化
- 可视化图表的使用误区

可视化图表的类型

- 可视化图表种类繁多，“我该使用哪种类型的图表”？



可视化图表的类型

➢ “我该使用哪种类型的图表”？——取决于受众和沟通目标

受众

- **知识水平**：专业人士可能需要更具技术性的图表，而一般公众可能更喜欢简单直观的设计
- **文化差异**：颜色和某些图形元素在不同的文化中可能具有不同的含义
- **关注点**：受众可能对某些数据点或信息特别感兴趣
- **偏好的呈现方式**：一些受众可能偏好交互式图形等

沟通目标

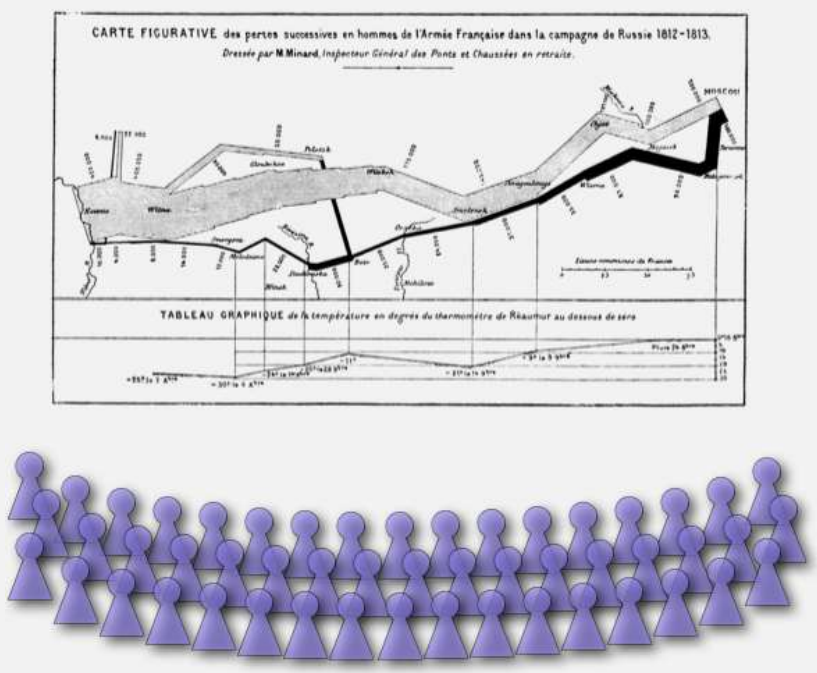
- **教育**：向受众解释复杂的概念或数据
- **报告**：传达项目进度、业绩结果或研究发现
- **说服**：影响受众的观点或促使他们采取行动
- **探索**：提供工具让受众自行探索数据或信息
- **讲故事**：通过数据和信息讲述一个引人入胜的故事

可视化图表的类型

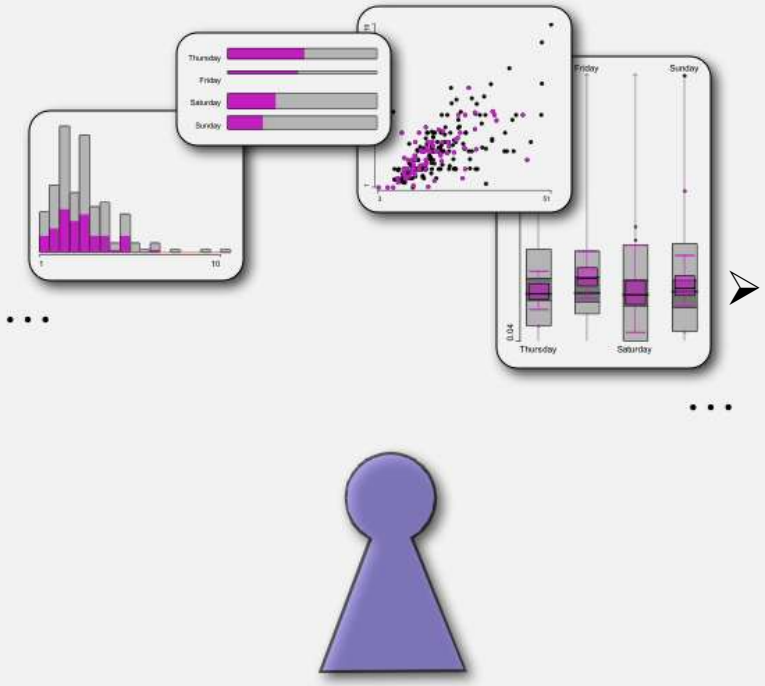
- “我该使用哪种类型的图表”？——取决于受众和沟通目标

展示

- 面向广大受众的单张图表以报告一个清晰的故事(storytelling)



Presentation



Exploration

探索

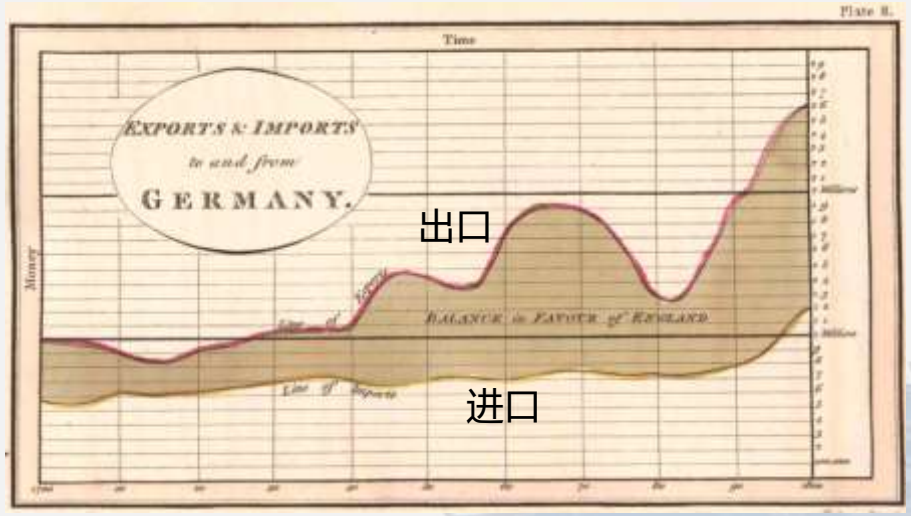
- 面向有限受众的多张图表以探索数据模式和辅助数据分析

统计数据图表的功能分类

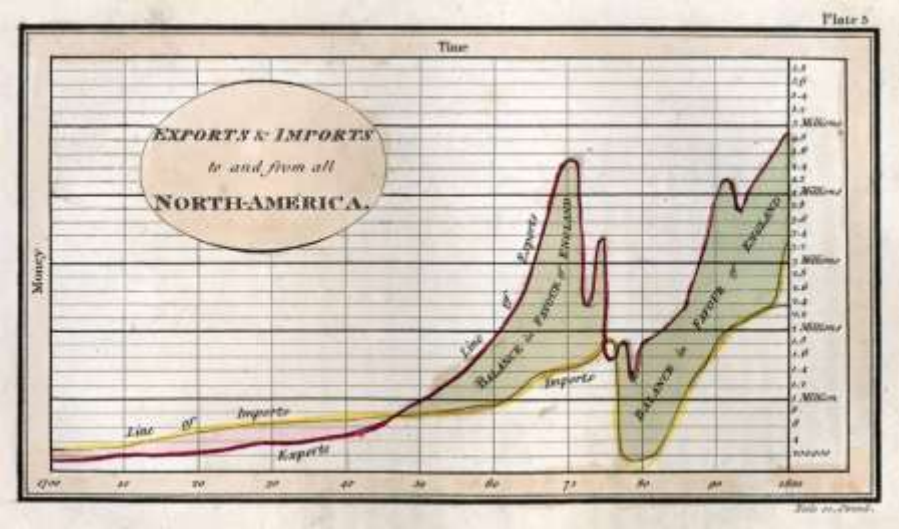
- **比较**：显示数据异同
- **比例**：使用大小或面积显示数值彼此或与整体之间的异同
- **关系**：显示数据之间的相互关系，或者显示两个或多个变量之间的相关性
- **层次结构**：显示实体在组织或系统中如何排列和排序
- **概念**：展示想法或解释概念
- **位置**：显示不同地理区域的数据
- **分布**：显示数据的分布范围或分布形状

统计图表——变化模式和规律

- **线图** (line graph)
  - **时间序列线图** (time series line graph) 由William Playfair 在1786年提出，可视化了英格兰与其他国家的贸易情况
  - 贸易差额可以视为出口（红色线）和进口（黄色线）曲线之间的差异
  - 你认为与哪个国家的贸易对英格兰更为有利?



英格兰 vs. 德国

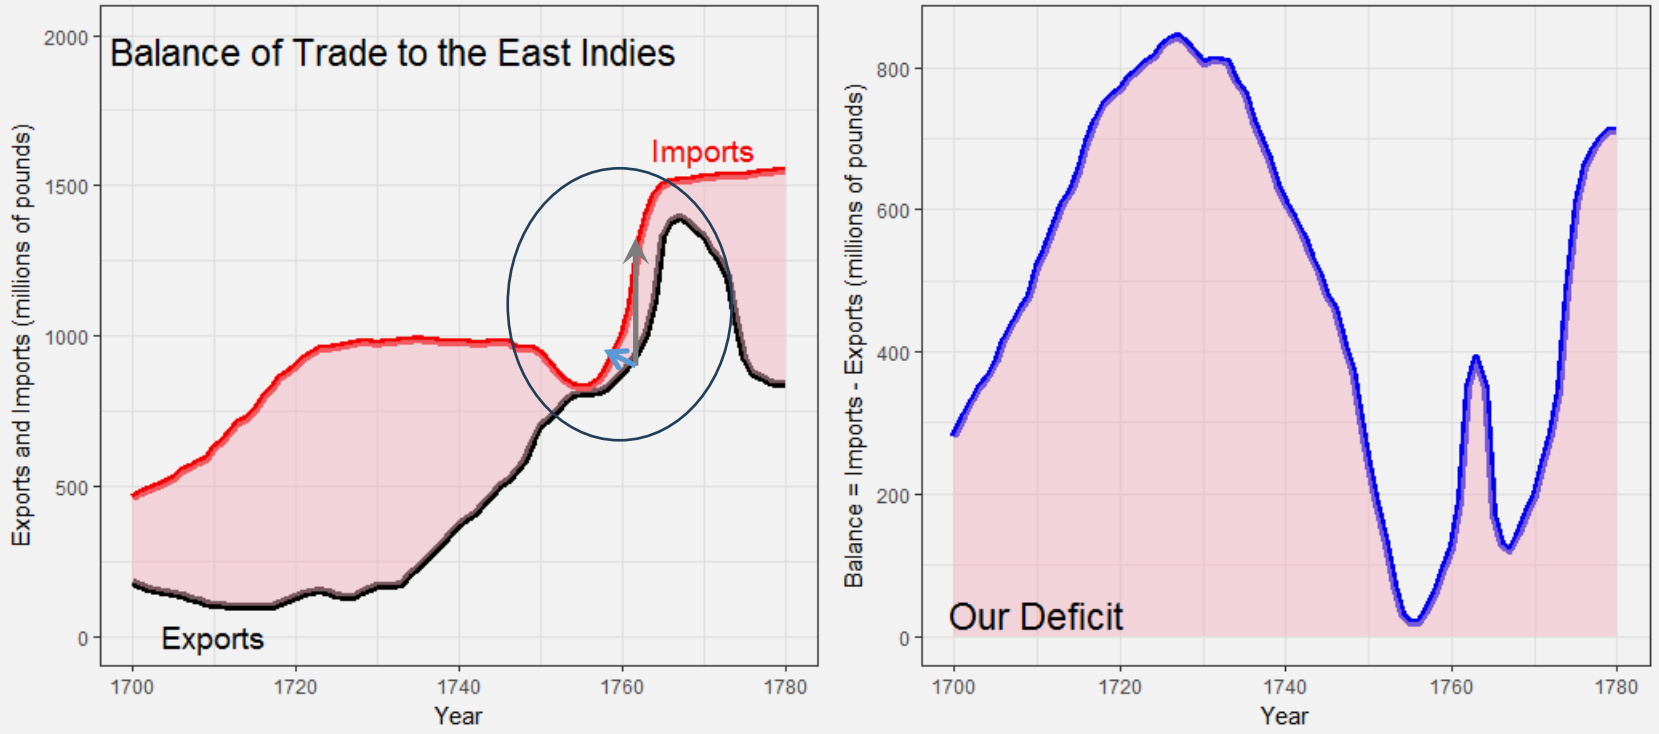


英格兰 vs. 北美

统计图表——变化模式和规律

- 然而，对两条曲线之间距离的判断可能存在偏差
- 人眼倾向于关注最短距离(shortest distance)而非纵向距离(vertical distance)

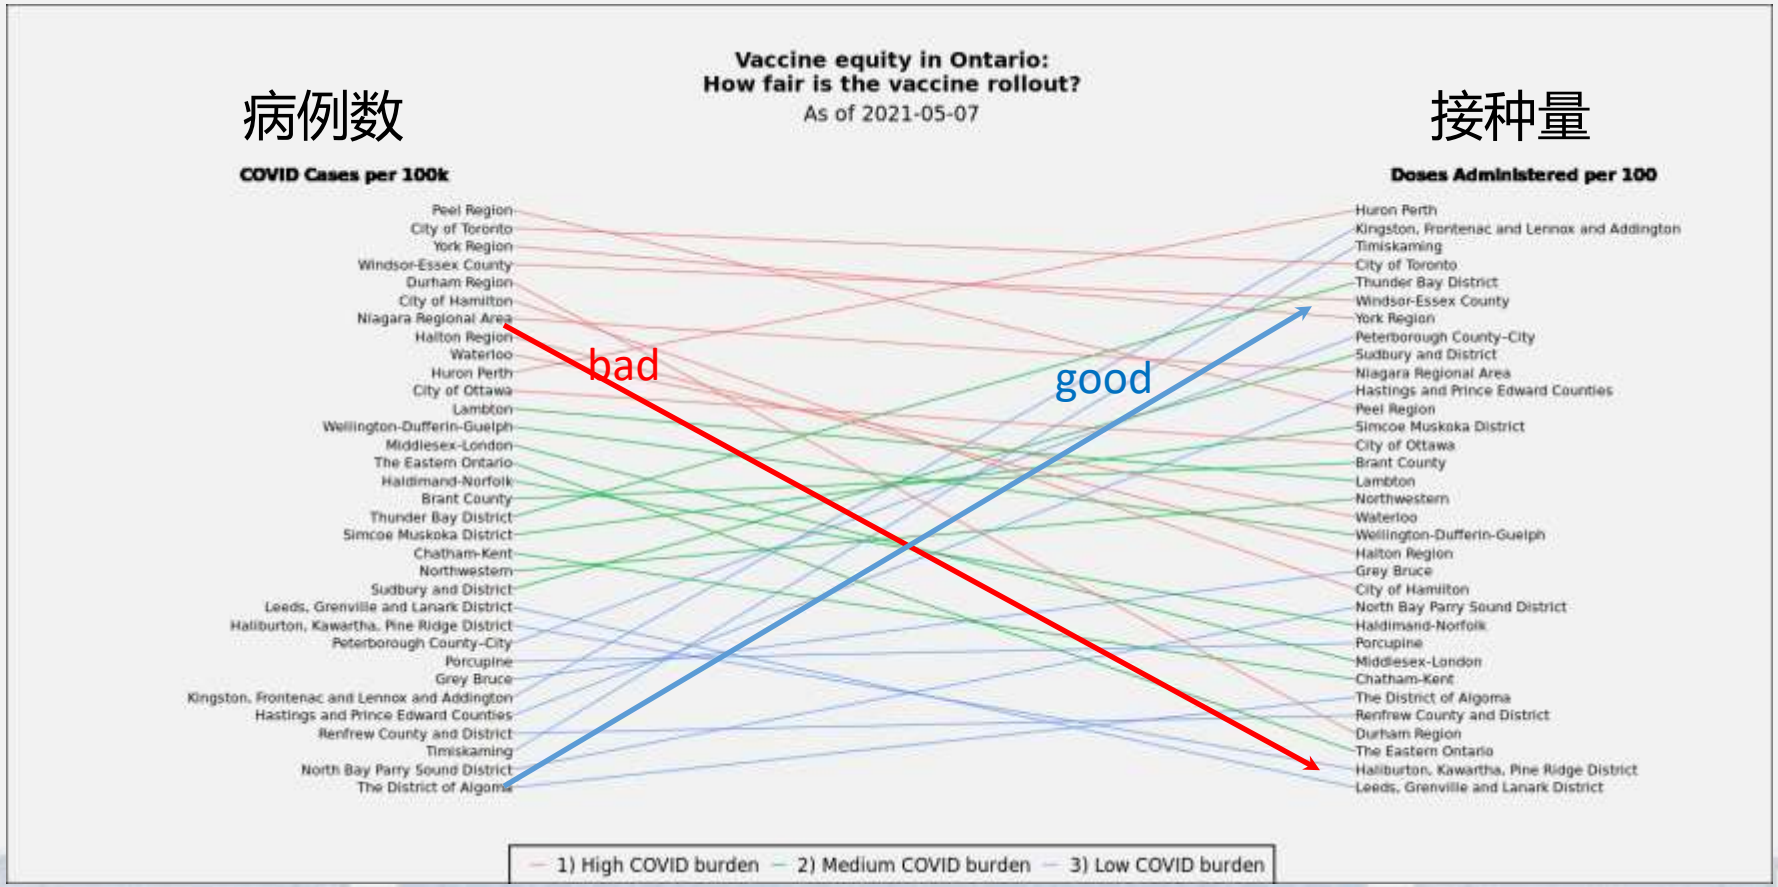
直接绘制贸易逆差（赤字）



统计图表——变化模式和规律

➢斜率图 (slope chart)

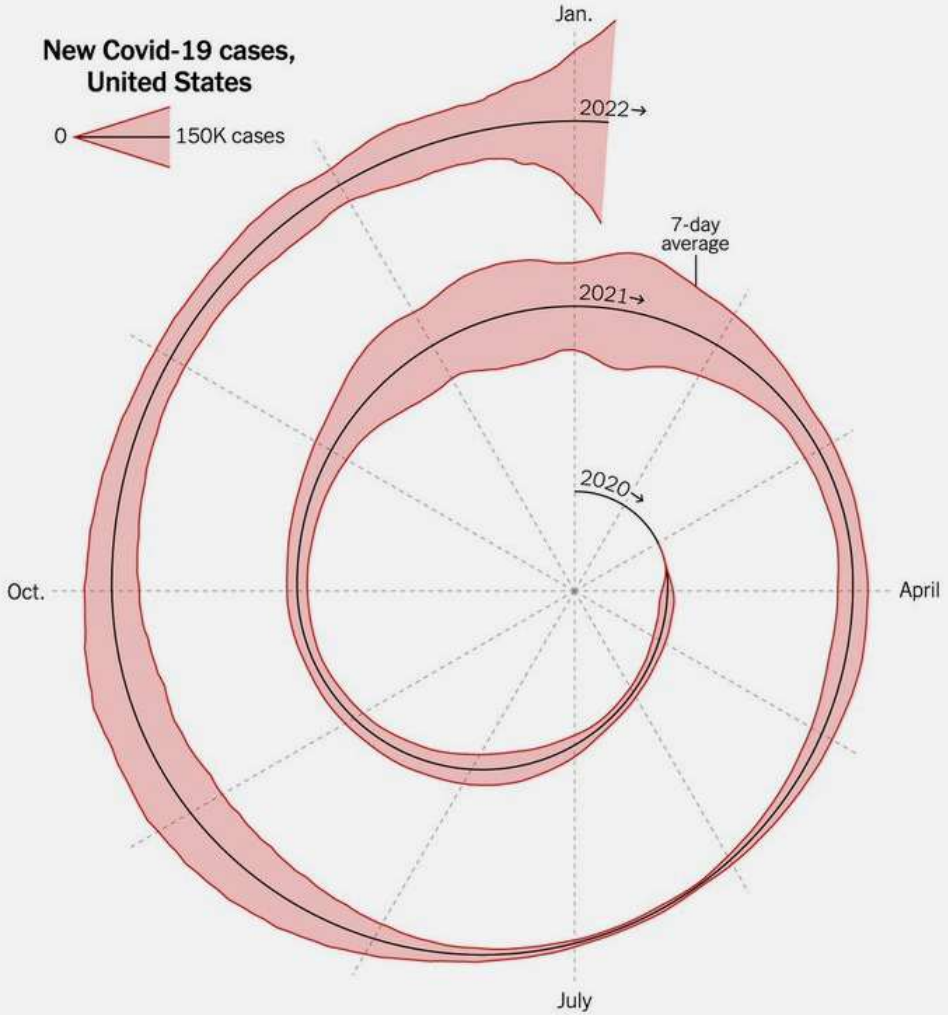
- “疫苗均衡” → 所有的线应该几乎平行
- 哪个地区在接种疫苗方面表现得更好?



统计图表——变化模式和规律

- **螺旋图** (spiral graph)
  - 也称为时间序列螺旋图，类似于在极坐标系(polar coordinate)中可视化变量随时间的变化情况
  - 适合用来显示大型纵向数据集(longitudinal data)在长时间段内的数据趋势，能有效显示周期性模式

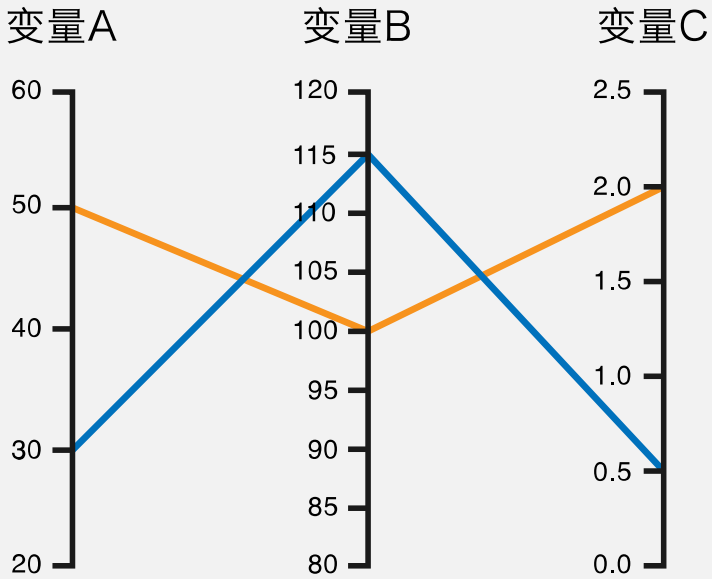




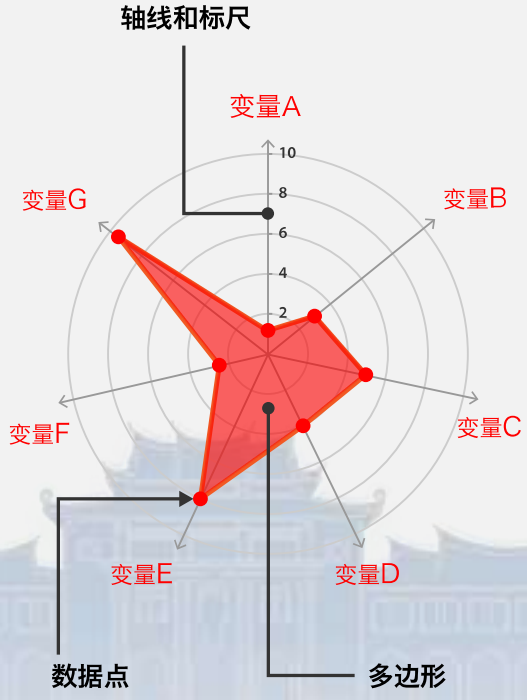
新冠疫情时期的新增病例数

统计图表——变化模式和规律

- **平行坐标图** (parallel coordinates plot)
  - 适用于多维数据可视化，常用来比较不同对象在若干相同维度上的差异。例如，比较同属性的若干产品
  - 每个变量都有自己的轴线，所有轴线彼此平行，各自可以有不同的刻度和测量单位，绘制一系列的直线穿越所有轴线来表示不同数值
  - 和**雷达图** (radar chart) 作用相似

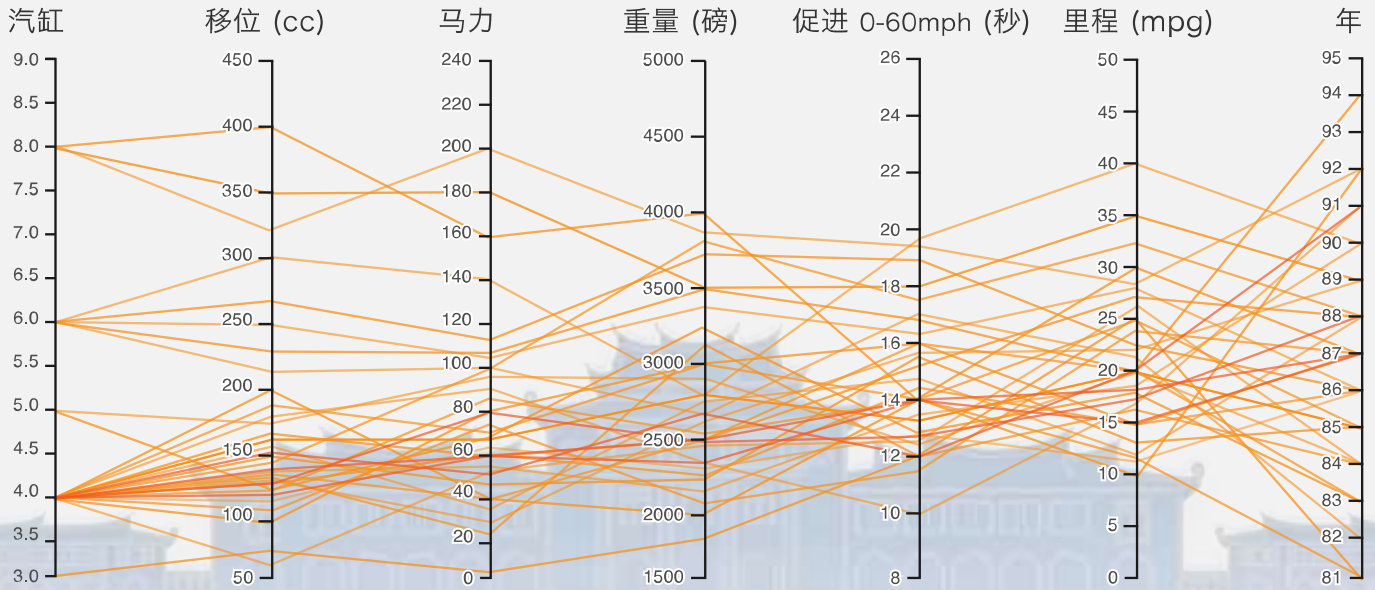


数据			
	变量A	变量B	变量C
项目1	50	100	2.0
项目2	30	115	0.5



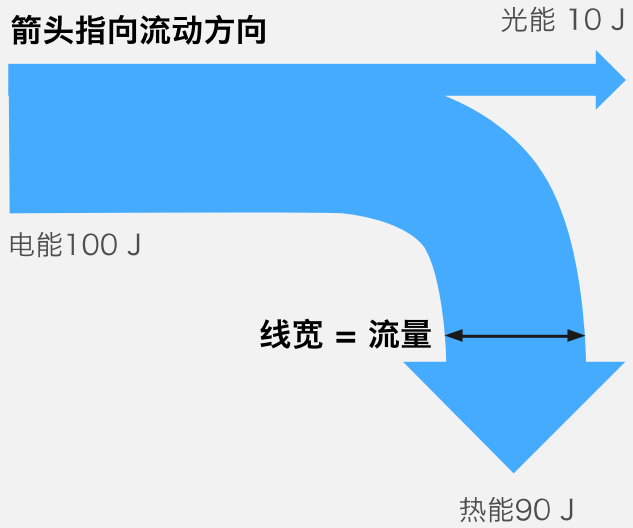
统计图表——变化模式和规律

- **平行坐标图** (parallel coordinates plot)
  - 轴线排列的顺序可能会影响用户如何理解数据，其中一个原因是相邻变量之间的关系会比非相邻的变量更加容易进行比较
  - 因此重新排列轴线可以帮助了解不同变量之间的模式或相关性
  - 平行坐标图的缺点是容易变得混乱，当数据密集时难以辨认不同对象
  - 解决这个问题的最好办法是通过交互可视化，突出显示所选定的一条或多条线，同时淡化所有其他线条，让注意力集中在感兴趣的对象，滤除干扰数据



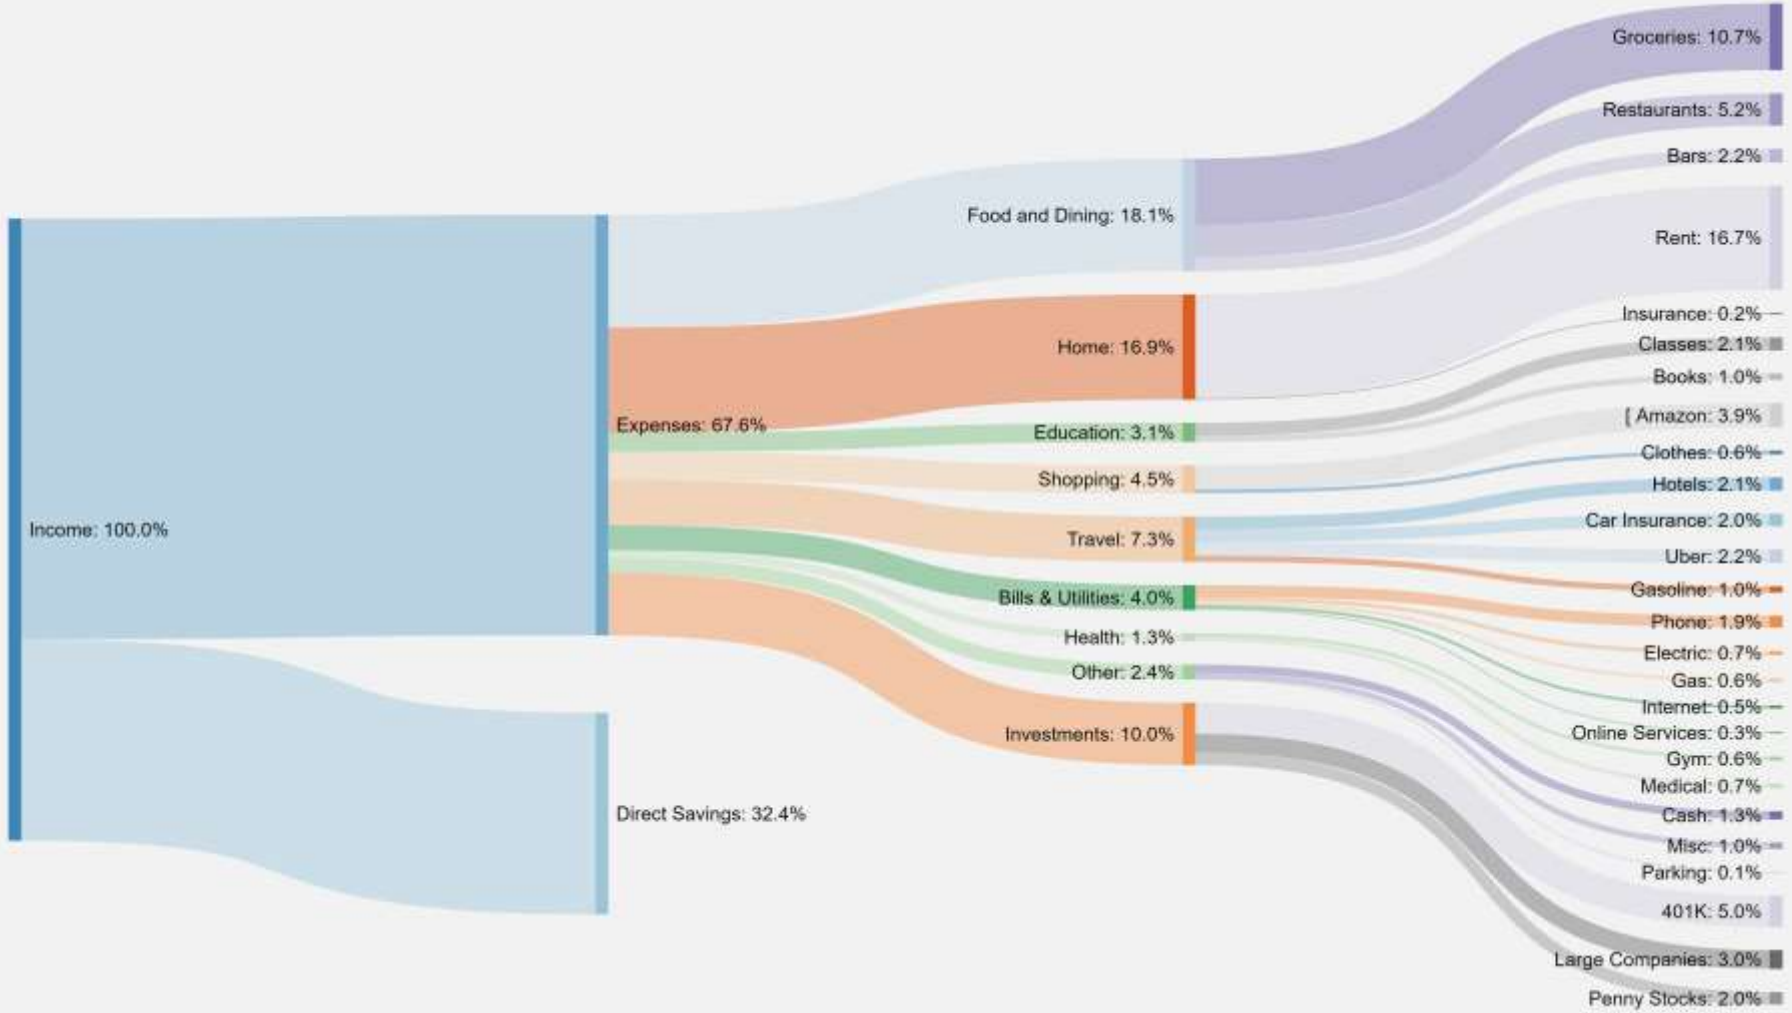
统计图表——变化模式和规律

- **桑基图** (Sankey diagram)
  - 显示数据流向和比例，例如能量、资金、人口或材料等
  - 常用于理解数据的流动、事件的过程或系统的运作模式
  - 箭头或线的宽度显示大小；箭头越大，流量也越大
  - 在每个流程阶段中，流向箭头或线可以组合在一起，或者往不同路径各自分开
  - 可用不同颜色来区分图表中的不同类别，或表示从一个阶段到另一个阶段的转换



统计图表——变化模式和规律

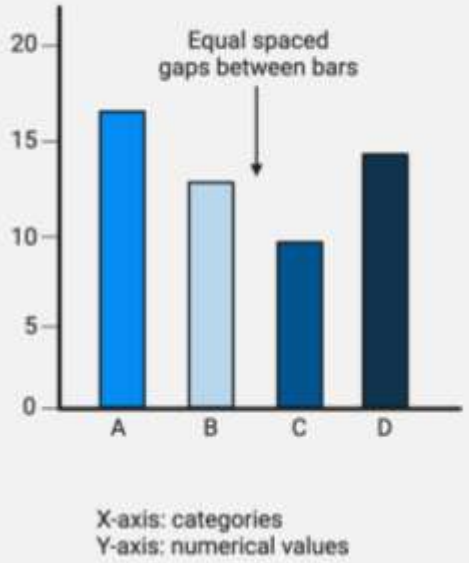
➢桑基图显示支出情况



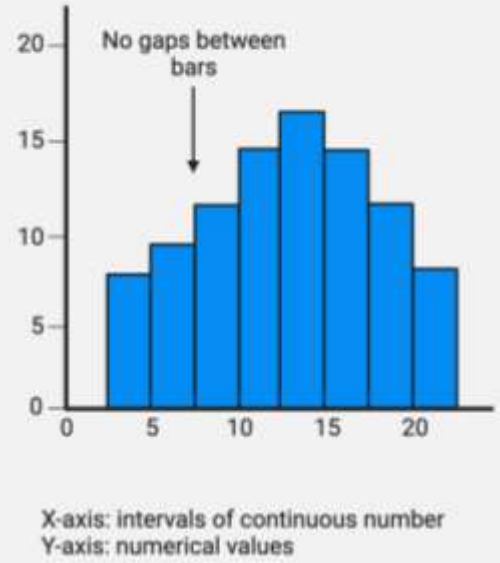
统计图表——分布情况

条形图 vs. 直方图

- 条形图用于展示**离散变量**的分布情况，每个条形代表一个类别，条形的长度表示该类别的数量或比例，条形图适合比较不同类别之间的数值大小
- 直方图用于展示**连续变量**的分布情况，通过不同的条形高度表示不同区间内数据点的频数、概率或概率密度，从而可以清晰地看到数据的分布形态，如正态分布、偏态分布等



条形图



直方图

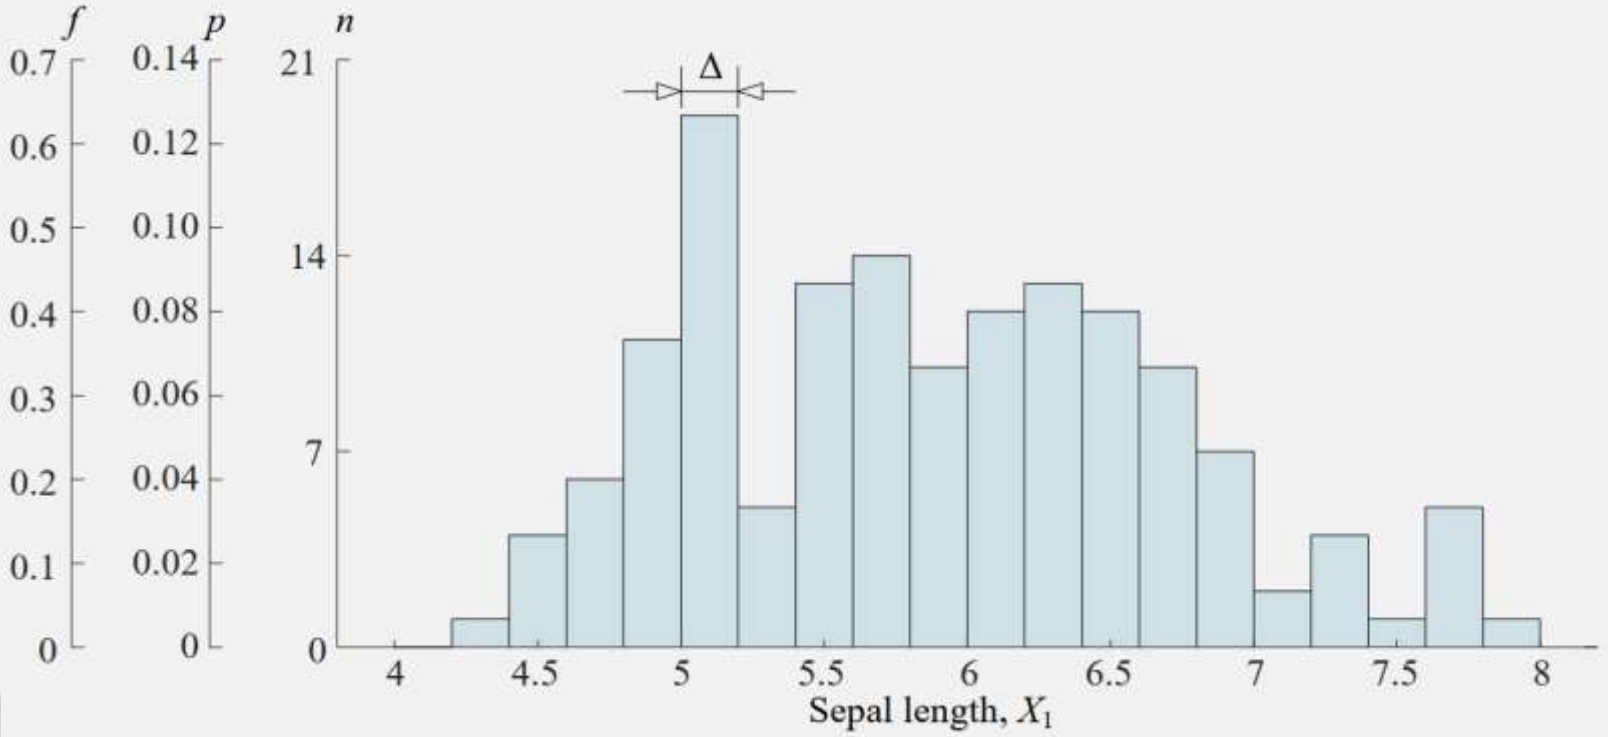
统计图表——分布情况

➢直方图 (histogram)

概率密度：概率除以组距；所有矩形面积之和为1

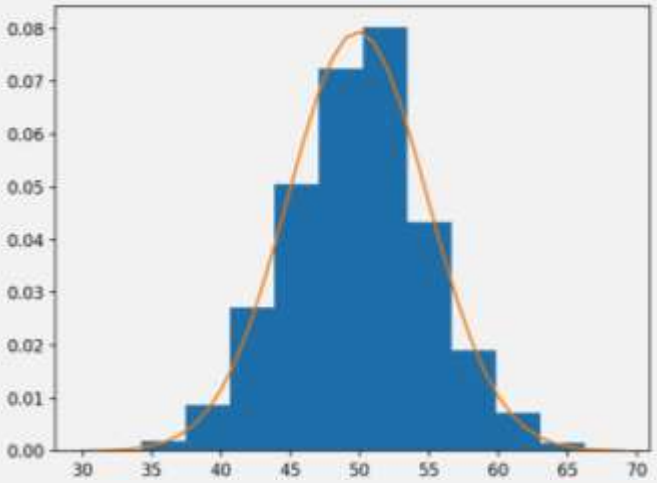
概率：频数除以样本总数；也称归一化直方图

频数：落在第i个区间内的样本数量n_i；所有频数之和为样本总数

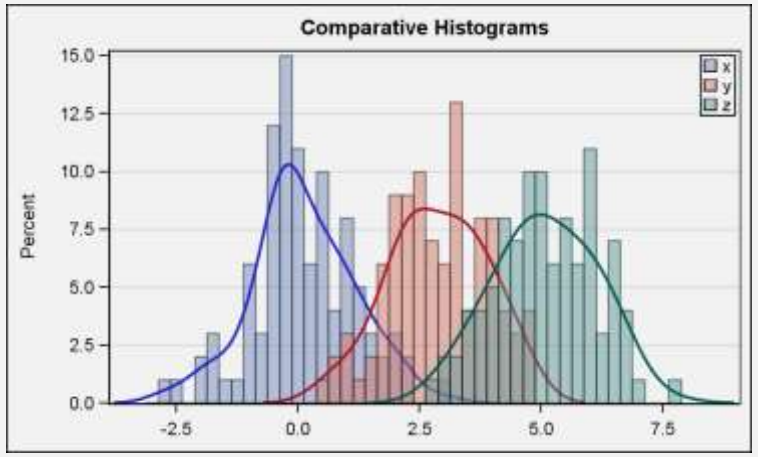


统计图表——分布情况

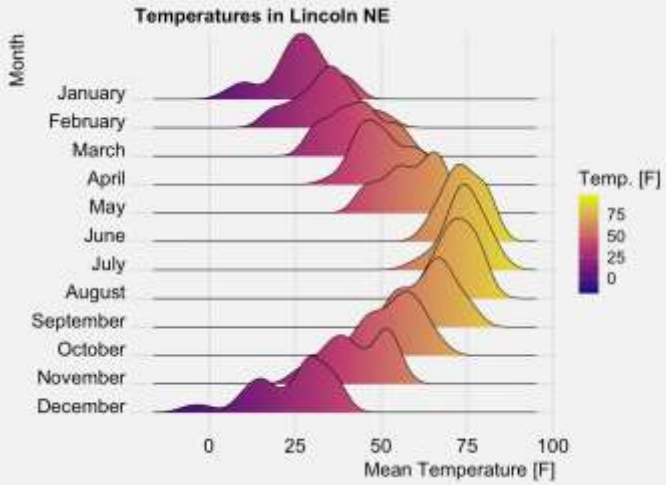
- **密度图** (density plot)
  - 使用平滑曲线显示数据的分布形状
  - 平滑曲线是如何得到的?



- 通过核密度(kernel density)估计得到概率密度函数图像



- 使用交叠的频率分布直方图及密度曲线来对比不同变量的分布情况——**交叠密度图** (overlapping density plot)



- 同一变量在不同类别上的多个密度分布有时也被称作**脊线图** (ridgeline plot)，显示了多个重叠的概率密度

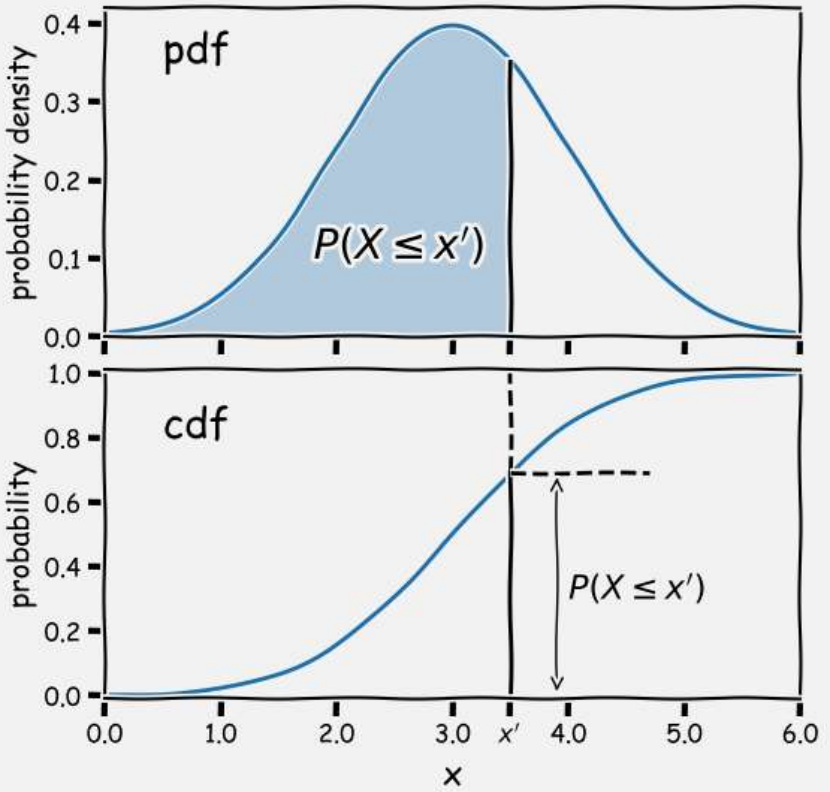
统计图表——分布情况

➢密度图 (density plot)

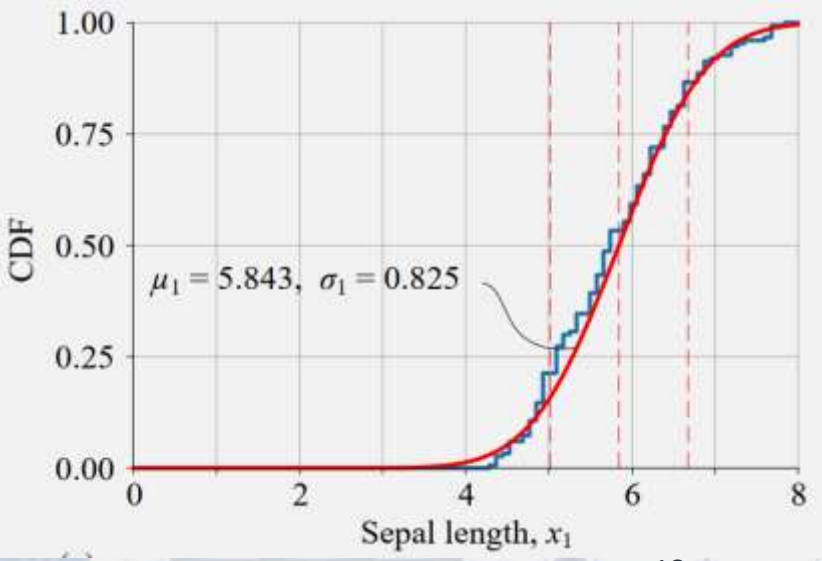
➢概率密度函数 (Probability Density Function, PDF) vs. 累积分布函数 (Cumulative Distribution Function, CDF) vs. 经验累积分布函数 (Empirical CDF, ECDF)

- PDF曲线的纵轴是概率密度
  - 非负
  - 面积为1（但是值可以大于1）
- CDF曲线的纵轴是概率值
- 浅蓝色区域的面积为概率值：

$$F(x') = P(X \le x') = \int_{-\infty}^{x'} f(t)dt$$



- ECDF描述样本数据的累积分布，本质是一个阶跃函数，常用来与理论CDF比较，以检验样本数据是否符合某种假设的分布



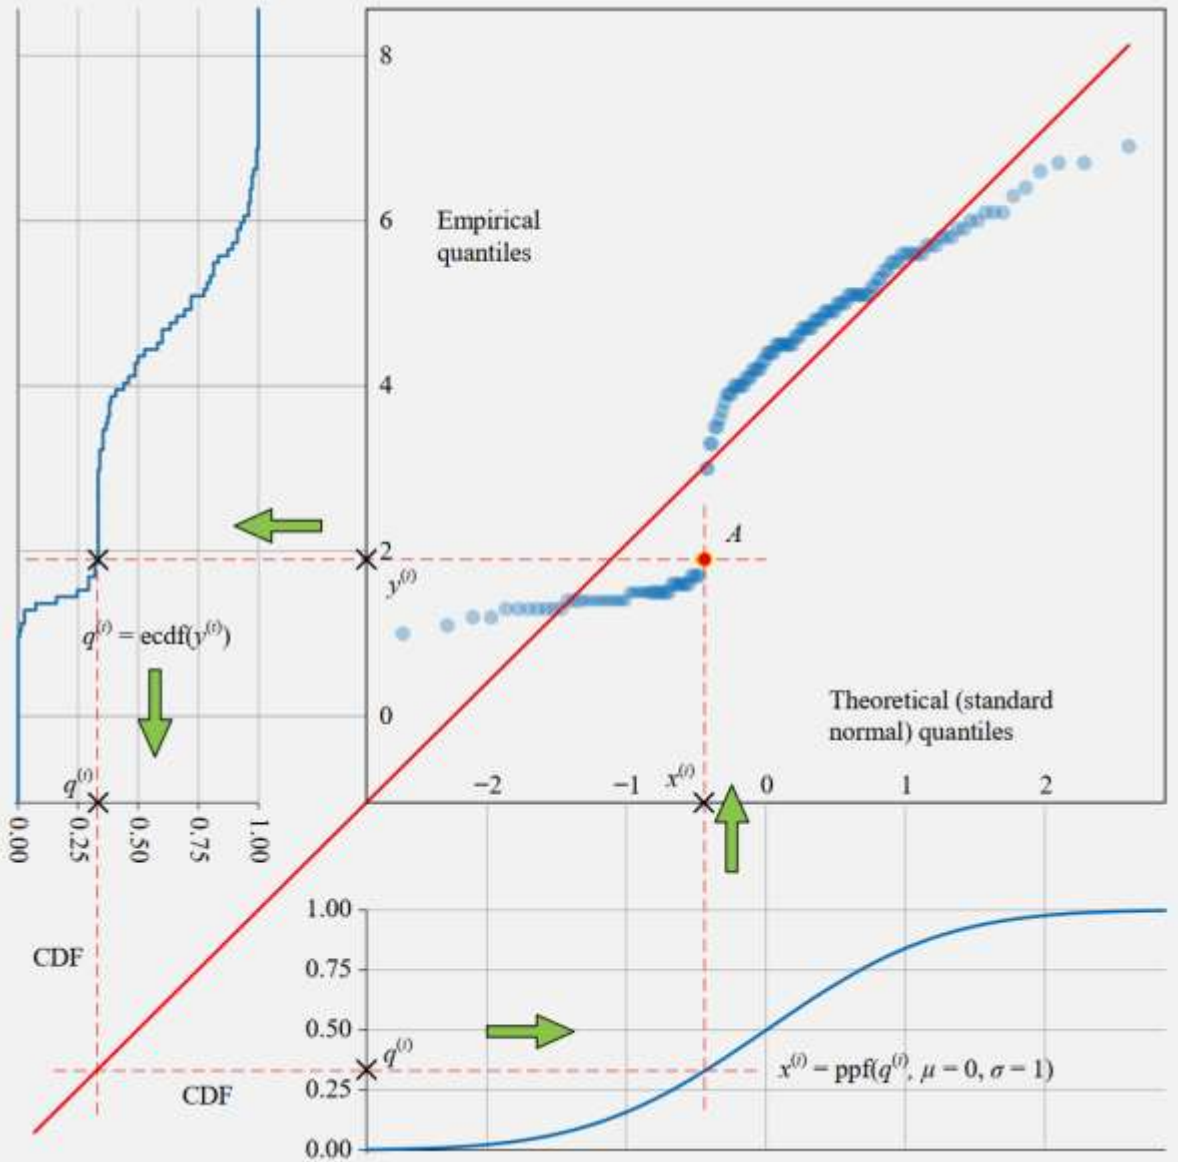
统计图表——分布情况

- **Q-Q图** (Quantile-Quantile plot)
  - Q代表分位数，常用于检查数据是否符合某个分布（例如标准正态分布），通常与正态性检验（normality test）结合使用
  - Q-Q图是一种散点图，纵轴为待检验样本的分位数，横轴一般为假定分布的分位数，多为正态分布，也可以是其他分布
  - Q-Q图将假定分布和待检验样本的分位数相互对应，从而比较它们之间的相似度
  - 如果样本符合假定分布，则Q-Q图呈现出一条近似于直线的对角线；否则呈现出偏离直线的曲线形状
  - 注意：轴刻度的缩放可能更改线的角度，影响对结果的解读

统计图表——分布情况

- Q-Q图如何绘制
  - 计算每个样本$y^{(i)}$对应的ECDF值
  - 根据标准正态分布CDF的逆函数，即百分点函数，将ECDF值转化为$x^{(i)}$
  - 得到点对$(x^{(i)}, y^{(i)})$

CDF函数的逆函数也称为百分点函数
(Percent Point Function, PPF)



统计图表——分布情况

- 对比正态分布，几种特殊分布的Q-Q图特点

直线　　⇒ 正态

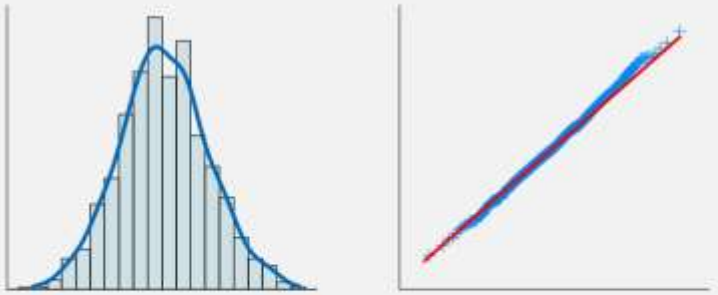
反“S”形 ⇒ 比正态厚尾 (峰度>3)

“S”形　⇒ 比正态薄尾 (峰度<3)

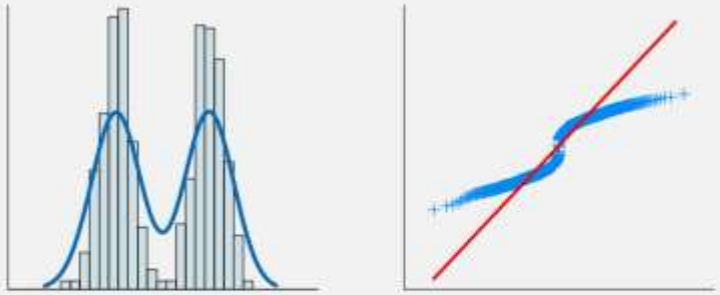
“凸”弯曲 ⇒ 右偏 (偏度>0)

“凹”弯曲 ⇒ 左偏 (偏度<0)

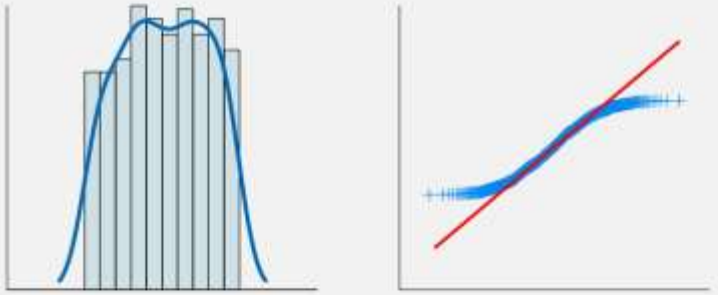
(a) normal distribution



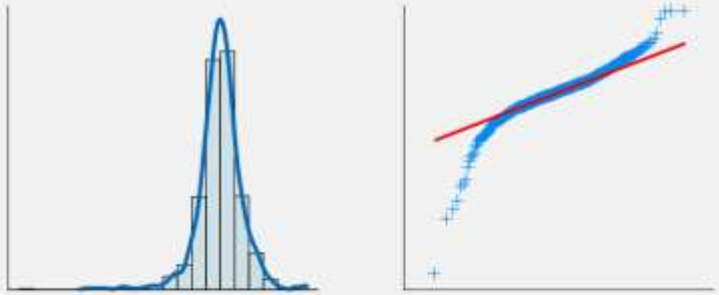
(b) two peaks



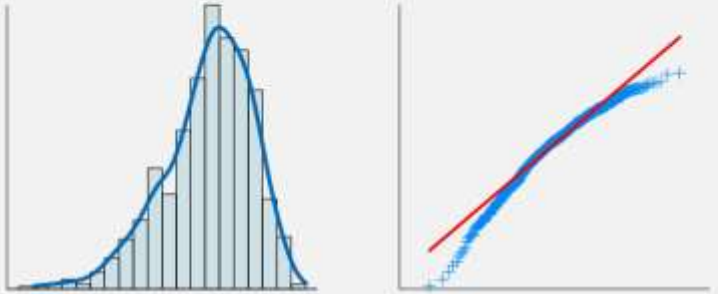
(c) uniform distribution



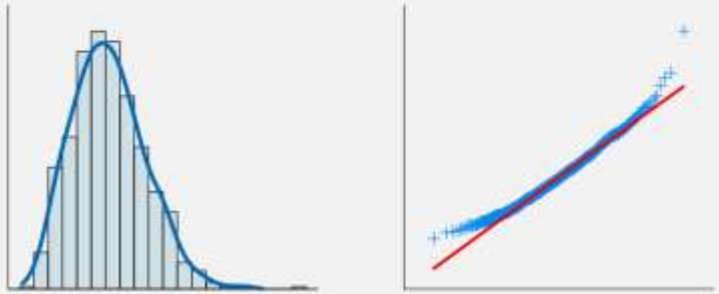
(d) fat tails



(e) negative/left skew



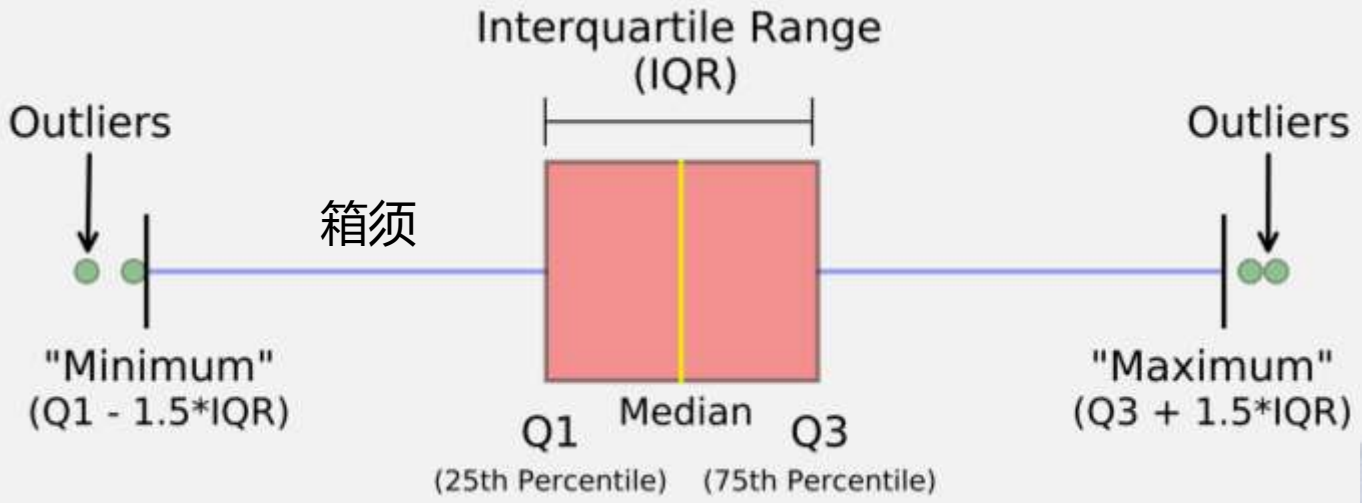
(f) positive/right skew



统计图表——分布情况

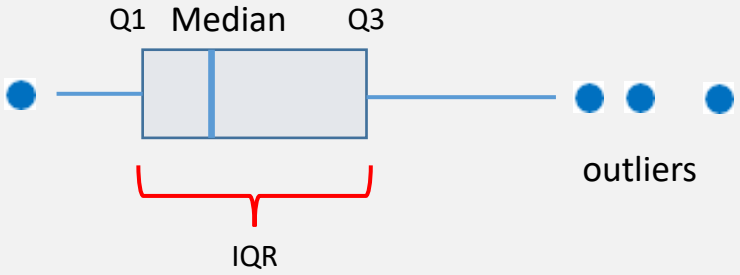
➢箱型图 (box plot)

- ➢ 又称箱线图、盒式图或盒须图，用于表示连续变量的分布情况
- ➢ 中位数（Median）：中心线表示数据的中位数
- ➢ 四分位数（Quartiles）：第一四分位数（Q1，25%分位数）、第三四分位数（Q3，75%分位数）。箱子的长度（即IQR，四分位数范围）表示中间50%数据的分布范围
- ➢ 箱须（Whiskers）：通常箱须的长度被定义为1.5倍的IQR
- ➢ 异常值（Outliers）：在箱须之外的点通常被认为是异常值



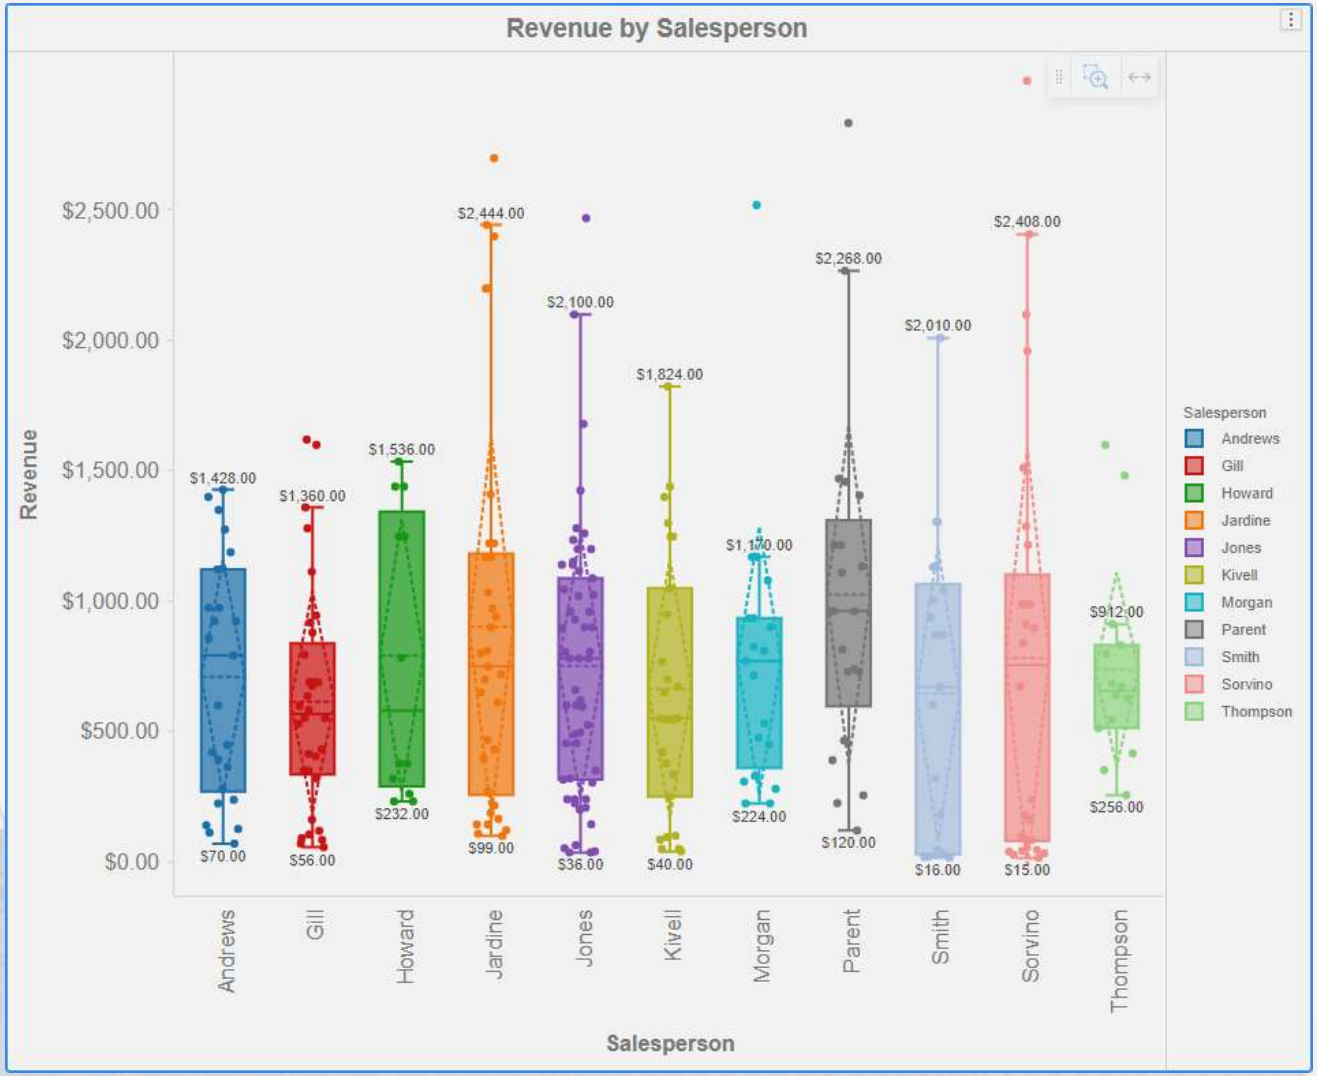
统计图表——分布情况

➢如何根据箱型图判断数据的分布形状?



- ➢ 数据分布是对称的吗?
- ➢ 数据出现偏斜了吗?
- ➢ 均值大于还是小于中位数?
- ➢ 偏度大于还是小于零?
- ➢ 左（负）偏还是右（正）偏?

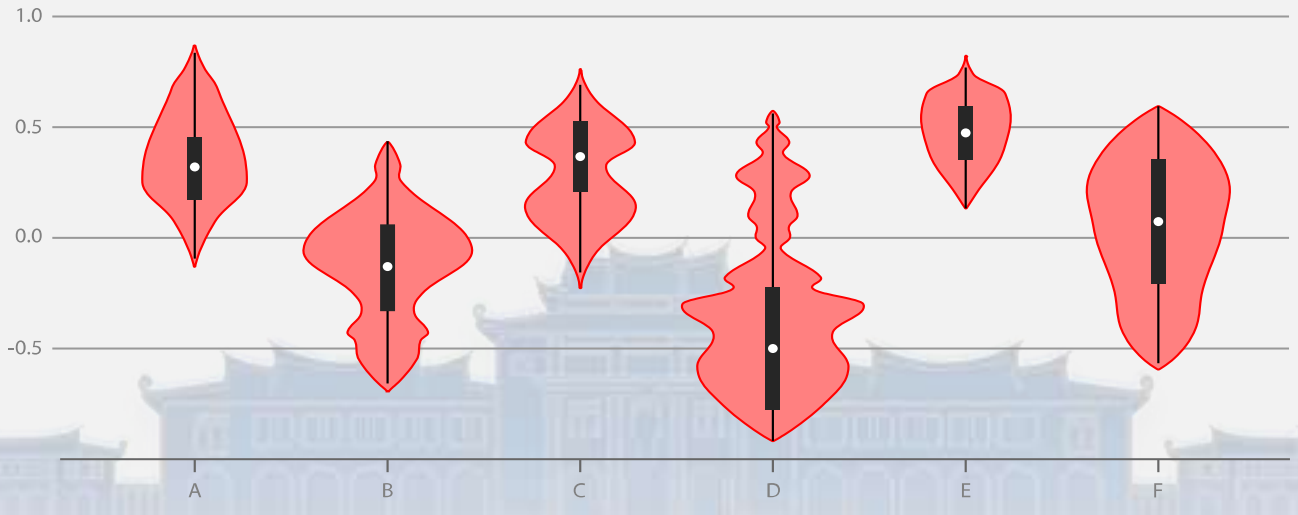
请评选你心目中的最佳销售



统计图表——分布情况

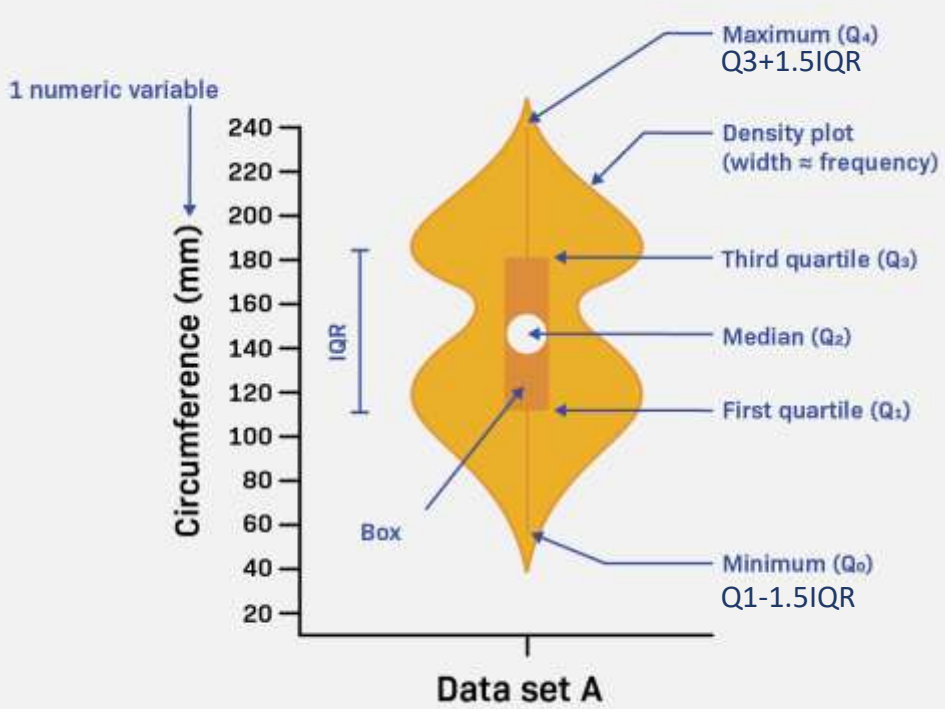
➢小提琴图 (violin plot)

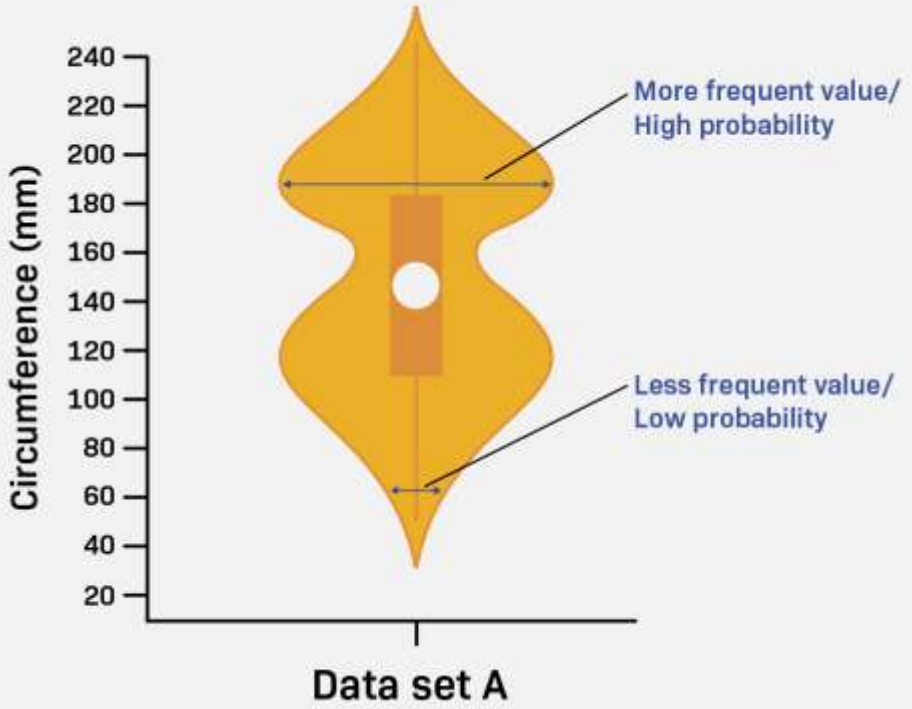
- ➢ 箱型图+密度图，用于展示连续变量的分布及其概率密度。优势在于不仅呈现了数据的描述性统计，而且还直观展示了数据分布的形状，包括多峰分布等复杂特征
- ➢ 中心标记：通常包括一个白点或横线，表示数据的中位数
- ➢ 箱型图：小提琴图的中心部分往往包含一个简化的箱型图，标示了Q1、Q3及IQR
- ➢ 密度估计：小提琴图的外形呈现数据的密度估计，展示数据在不同值上的密度分布。图形两侧关于中心轴对称，形似小提琴。密度越大，小提琴的部分越宽；相反，密度越小，部分越窄



统计图表——分布情况

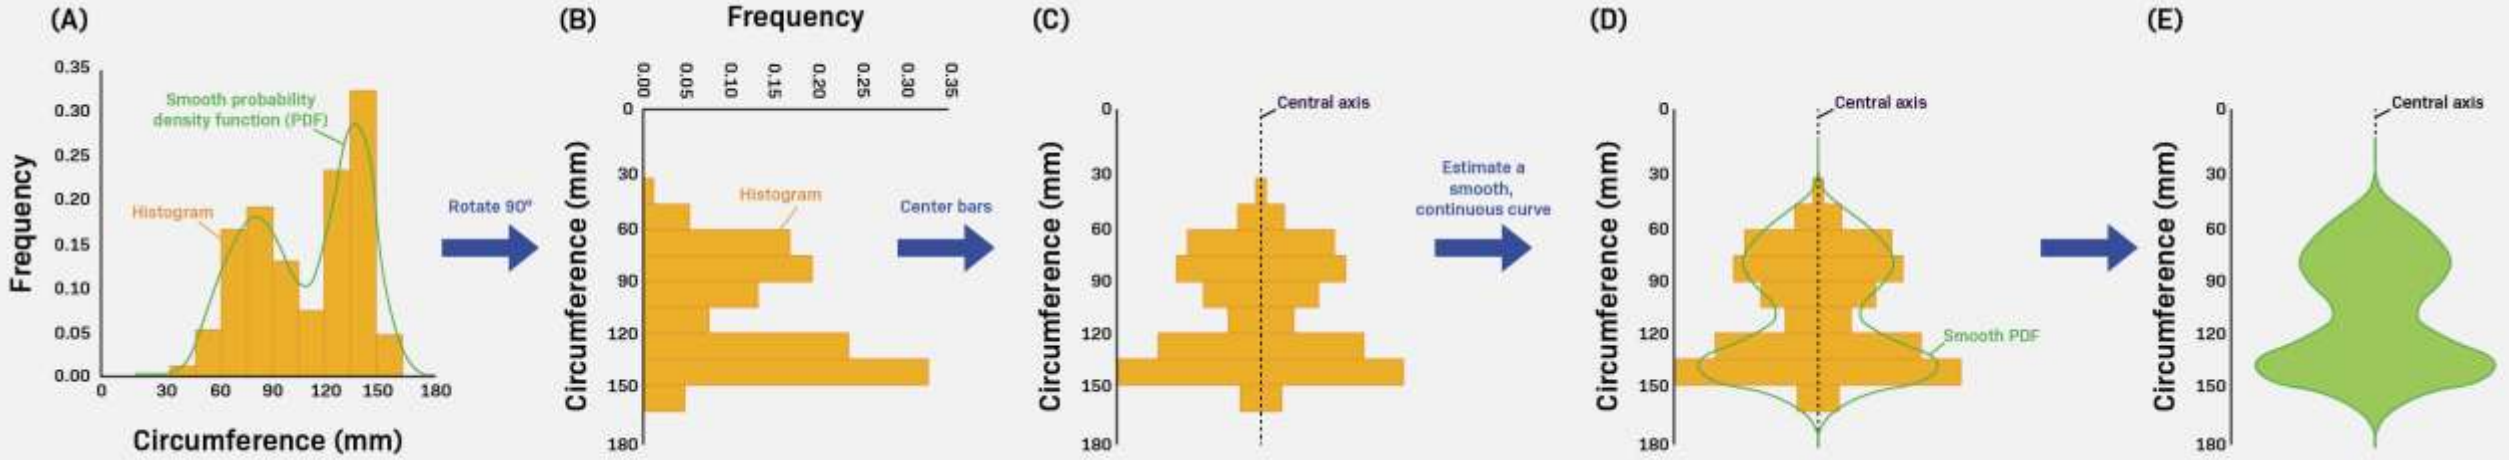
- **小提琴图** (violin plot)
  - 密度图的宽度显示了每个值出现的频率，越宽（窄）则出现频率越高（低）





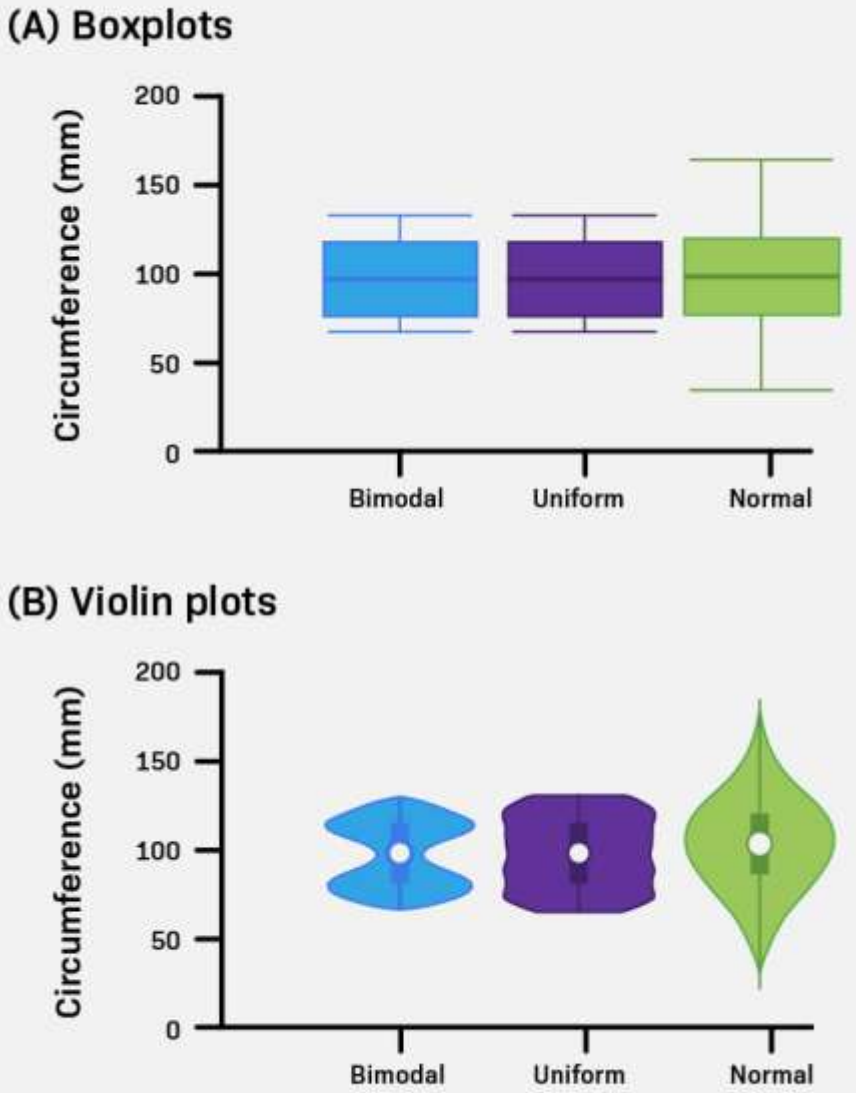
统计图表——分布情况

- **小提琴图** (violin plot)
  - 小提琴形状可以看作是一个旋转、居中和平滑的直方图



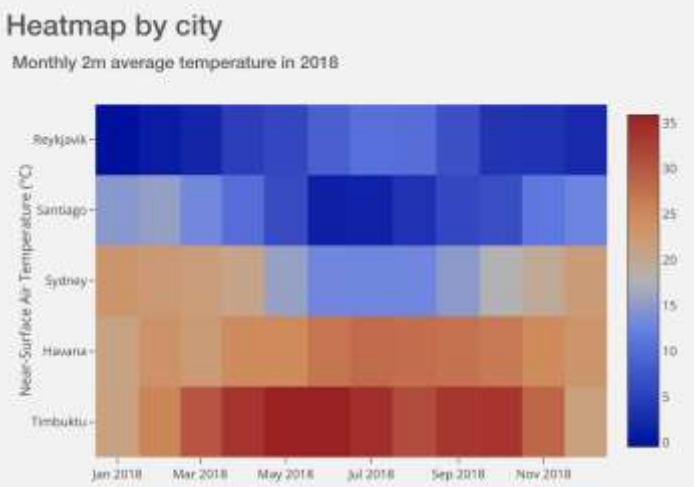
统计图表——分布情况

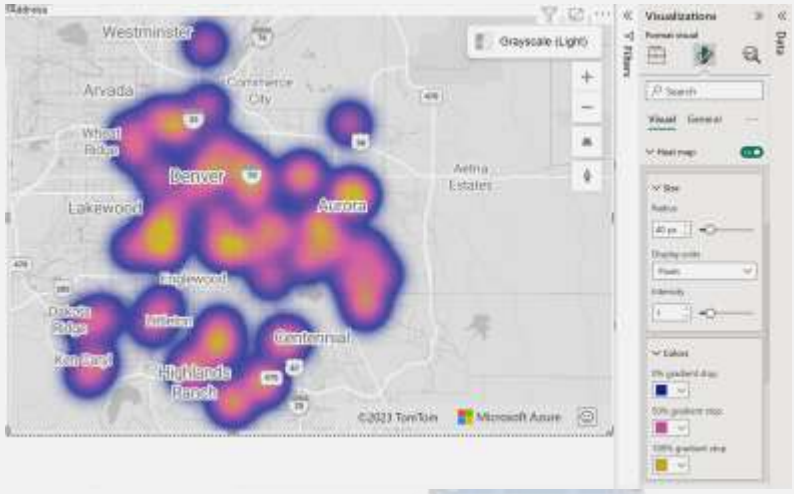
- **小提琴图** (violin plot)
  - 箱型图无法区分单峰和双峰(bimodal)数据
  - 但是小提琴图清楚地显示了数据的分布模式，适用于可视化多峰数据

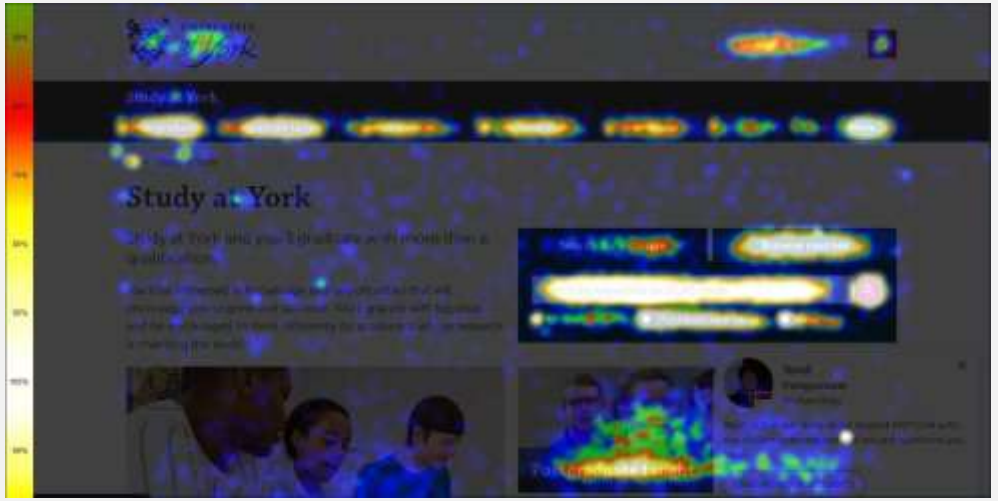


统计图表——分布情况

- **热力图** (heatmap)
  - 表示数据点在某一区域内的分布和密度，数据值的大小通常通过颜色的不同来展示，颜色越“热”（暖色调越强）表示该区域的数据值越高，颜色越“冷”（冷色调越强）表示数据值越低



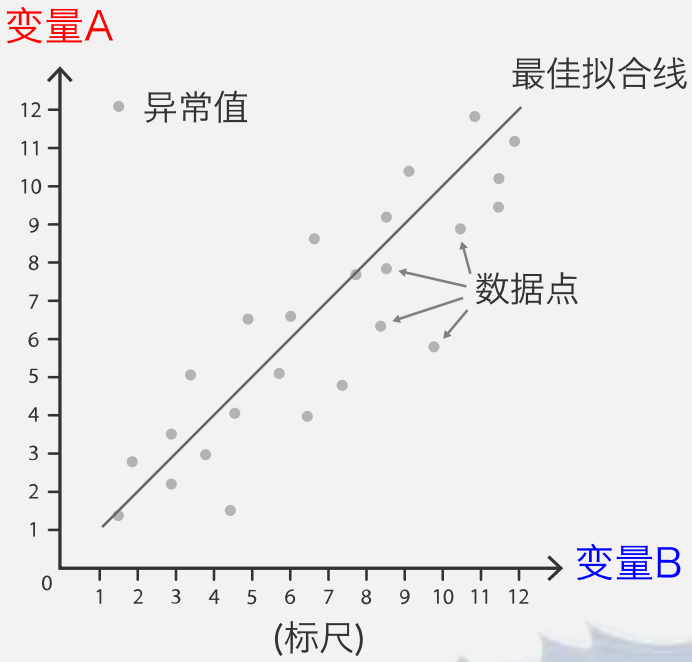


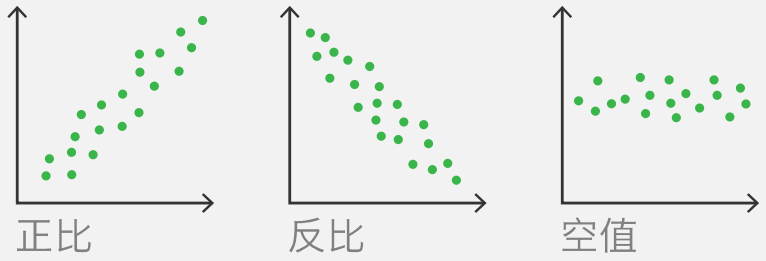


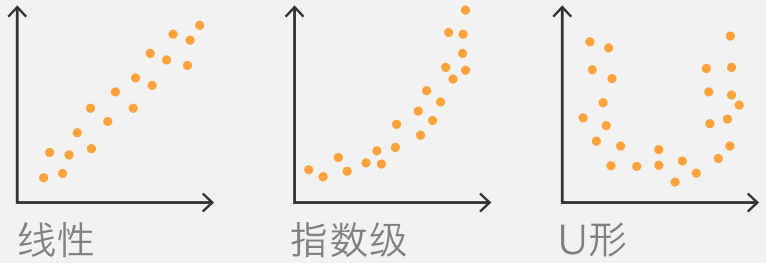
统计图表——相互关系

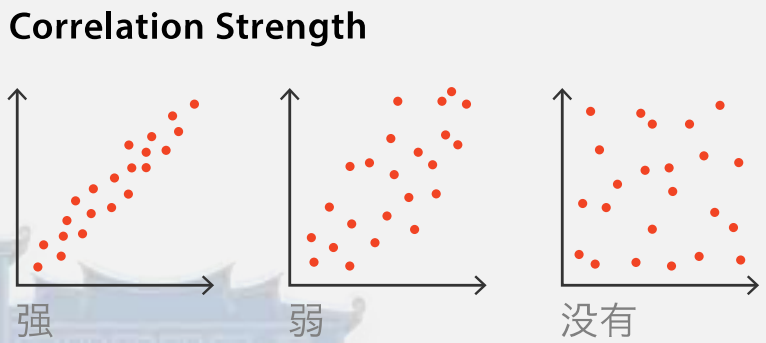
➢散点图 (scatter plot)

- ➢在笛卡尔坐标系显示两个变量的数值
- ➢可视化两个变量之间的关系和相关性



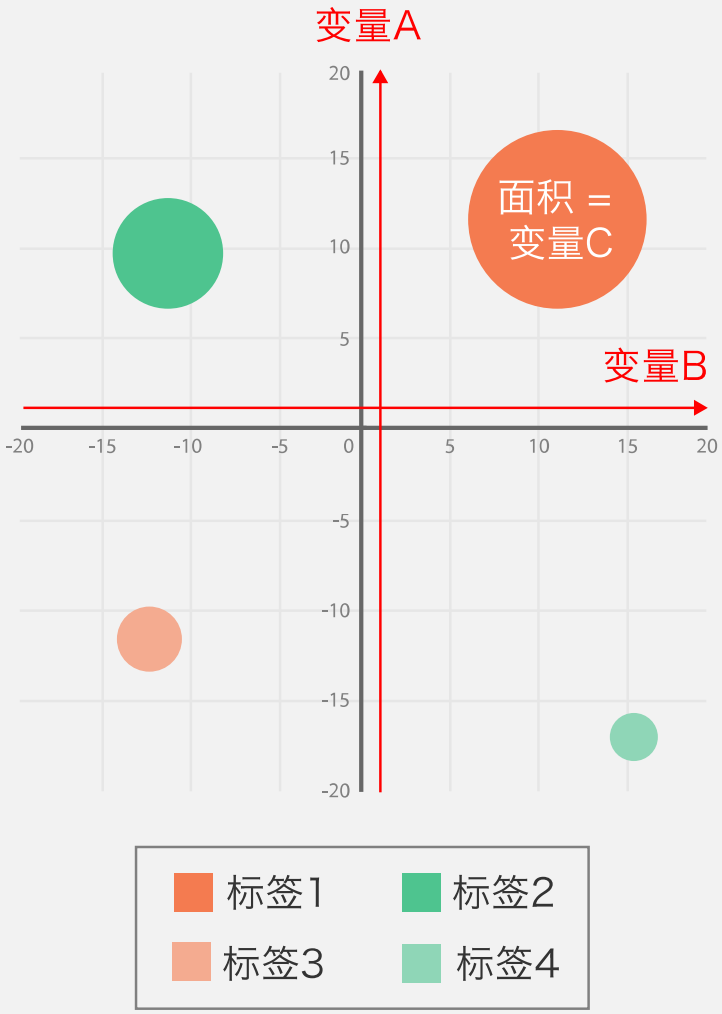






统计图表——相互关系

- **气泡图** (bubble plot)
  - 气泡图结合了散点图和比例面积图
  - 气泡图使用笛卡尔坐标系来绘制数值点， X 轴和 Y 轴代表不同变量，但与散点图不同的是，每一点都会分配一个标签或类别
  - 每个数值点以其圆形面积表示第三个变量；也可以用颜色来区分不同类别或表示其他数据变量
  - 气泡图通常用来比较和显示已标记/已分类圈圆之间的关系，可用于分析模式或相关性



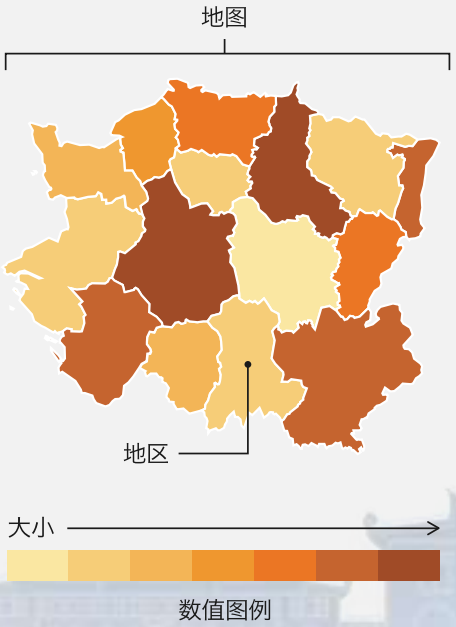
圆面积 = π × 半径^2

圆直径 = (平方根(面积 / π)) x 2

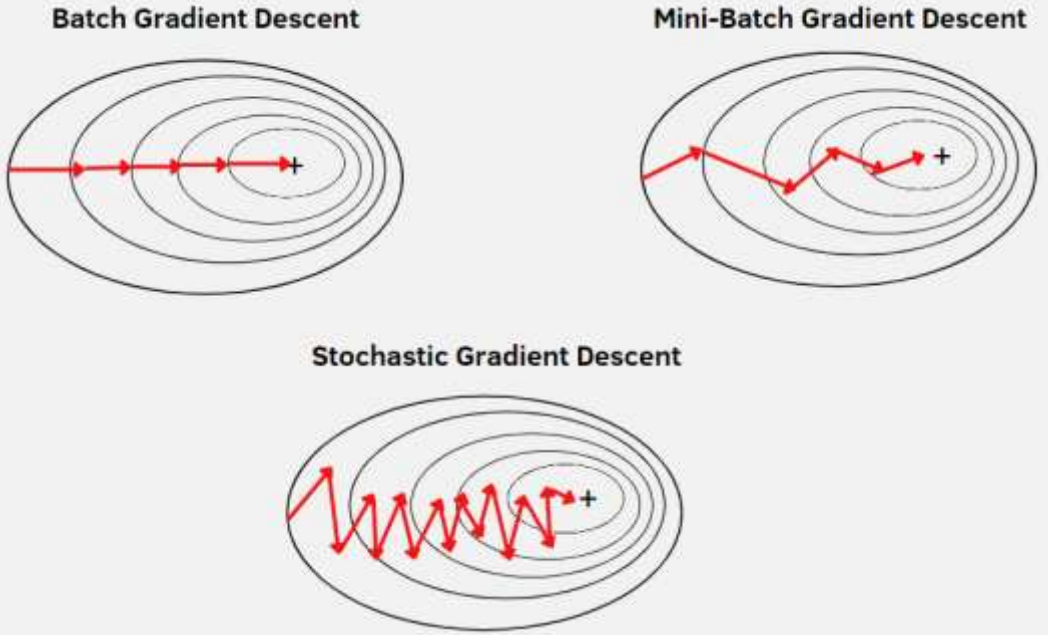
专题地图

- **专题地图** (thematic map) 显示地图或地理框架上的定量或定性变量，常用于地理空间可视化和地理空间统计分析领域
- 专题地图大多数是数字到视觉变量的直接映射
- 专题地图的基本类型：

地区分布图 (choropleth map)



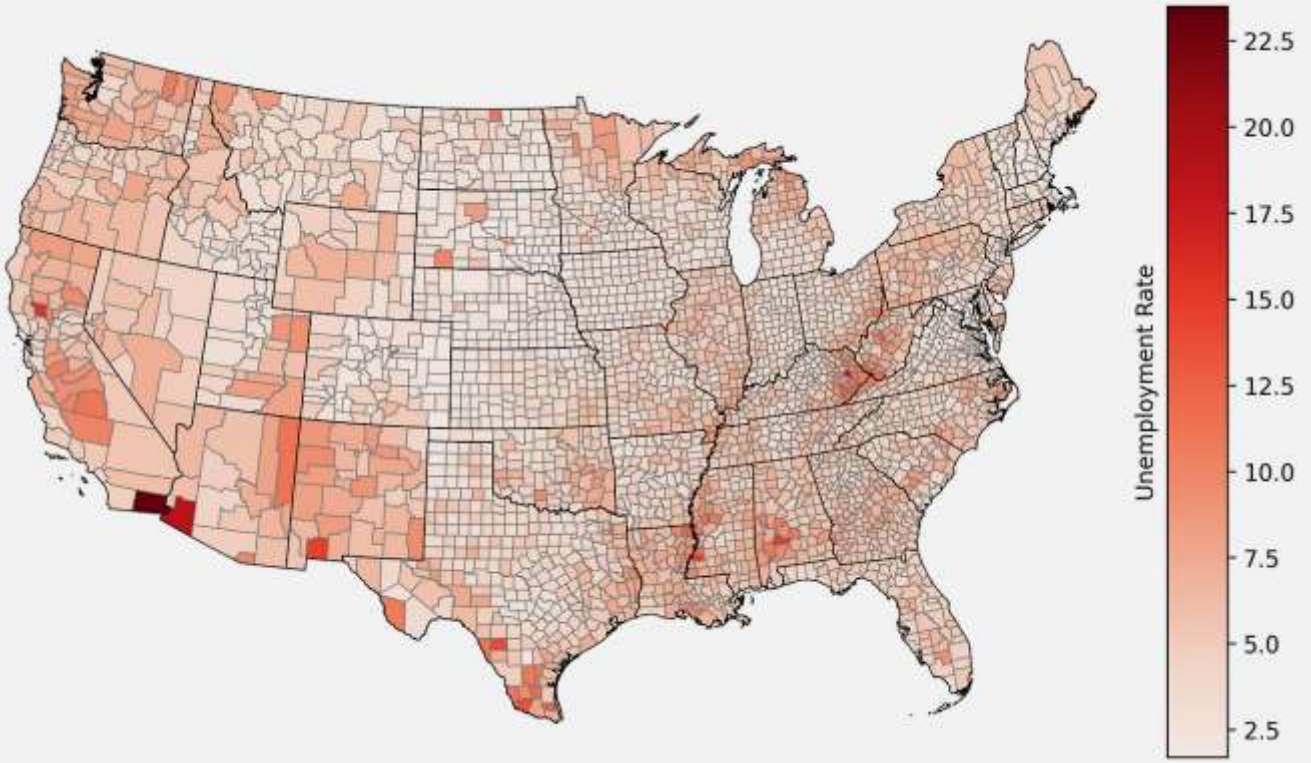
等值线图 (isopleth map)



专题地图

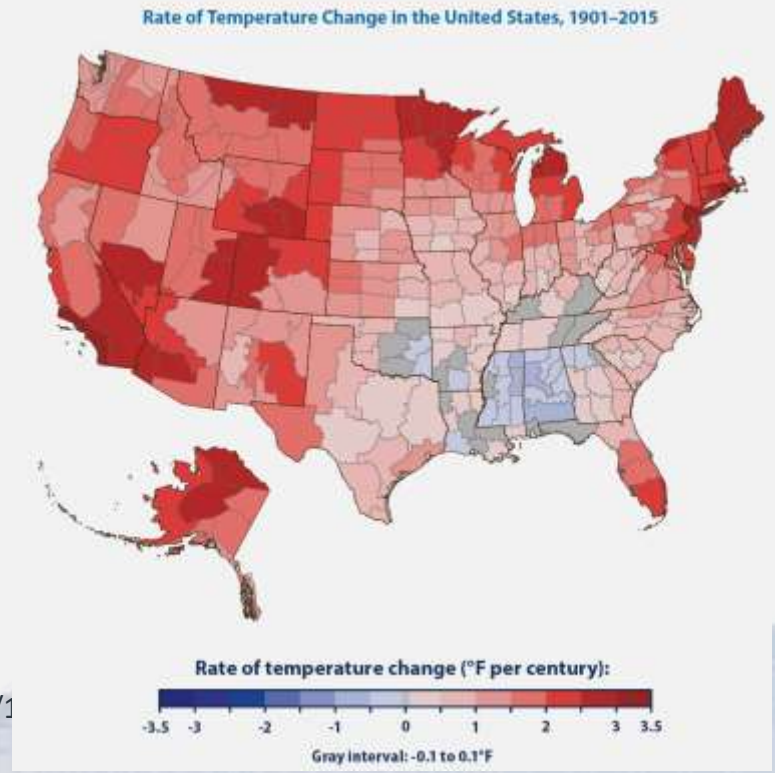
➢地区分布图 (choropleth map)

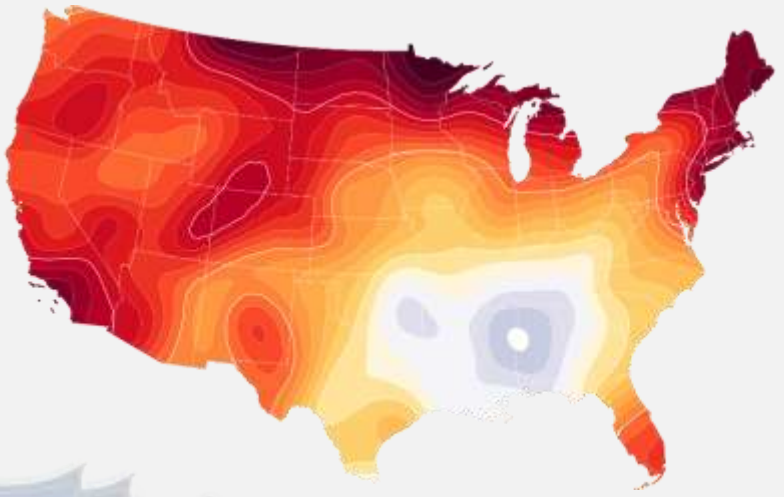
- ➢ 通常用来显示不同地理区域（不同颜色或图案）与数据变量之间的关系，并把所显示位置的数值变化模式进行可视化处理
- ➢ 使用颜色的缺点之一是无法准确读取或比较地图中的数值
- ➢ 绘制时的常见错误：对原始数值（例如人口）进行运算，而不是使用归一化数值（例：计算每平方公里的人口）



专题地图

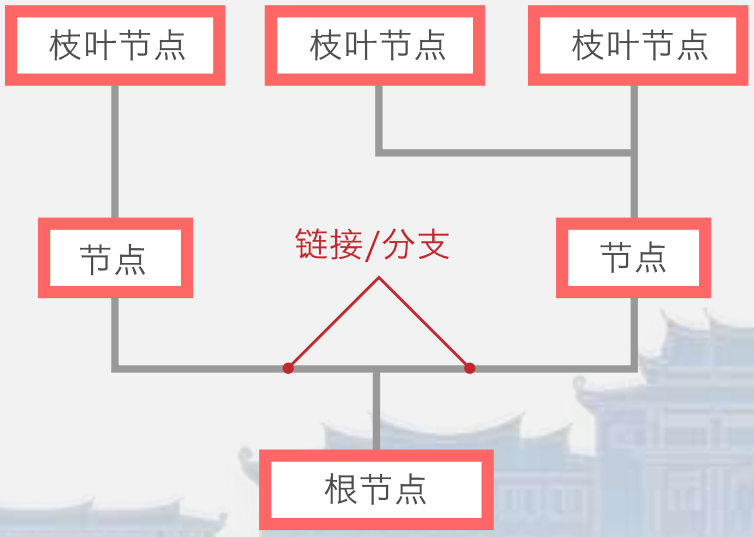
- 等值线图 (isopleth map)
  - 有时也被称为轮廓线图(contour map)或等高线图
  - 等值线图忽略了行政区域边界，以平滑曲线描绘地理空间上特定现象的恒定轮廓，是一种地理平滑

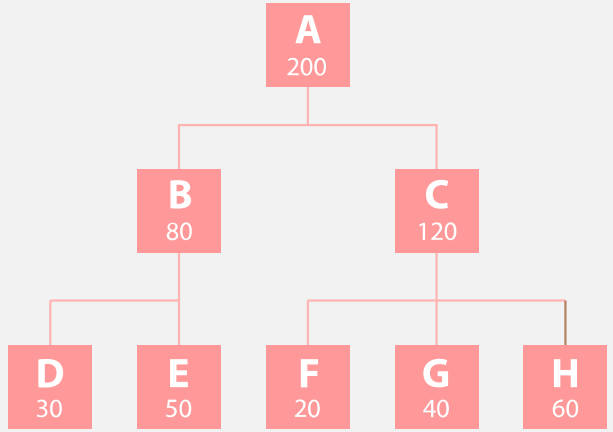


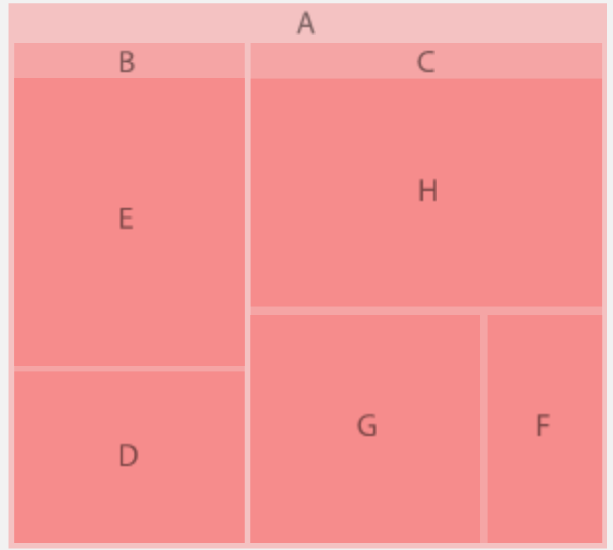


网络和树形可视化

- **树形图** (tree diagram)
  - 通过树状结构表示层次结构，通常由没有上级或父级成员的元素开始（根节点），然后加入中间节点，再用线连在一起，称为分枝，表示成员之间的关系和连接
  - 最后是枝叶节点（或称为末端节点），是没有子节点的成员



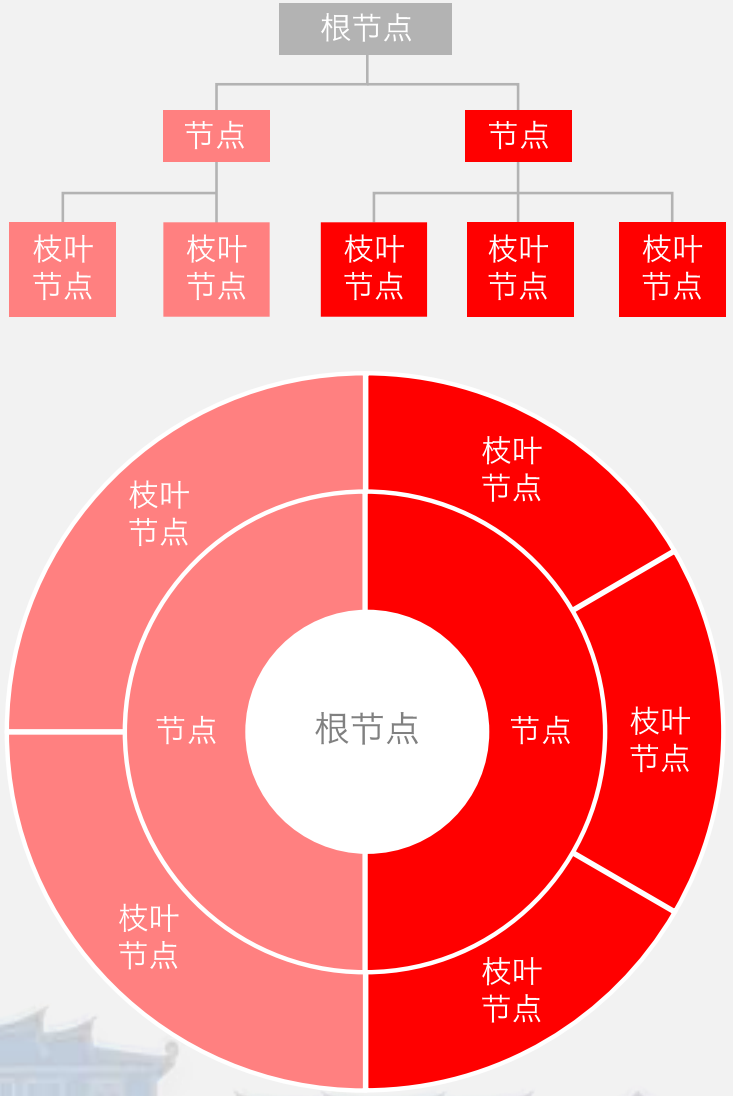




利用嵌套式矩形显示树形结构

网络和树形可视化

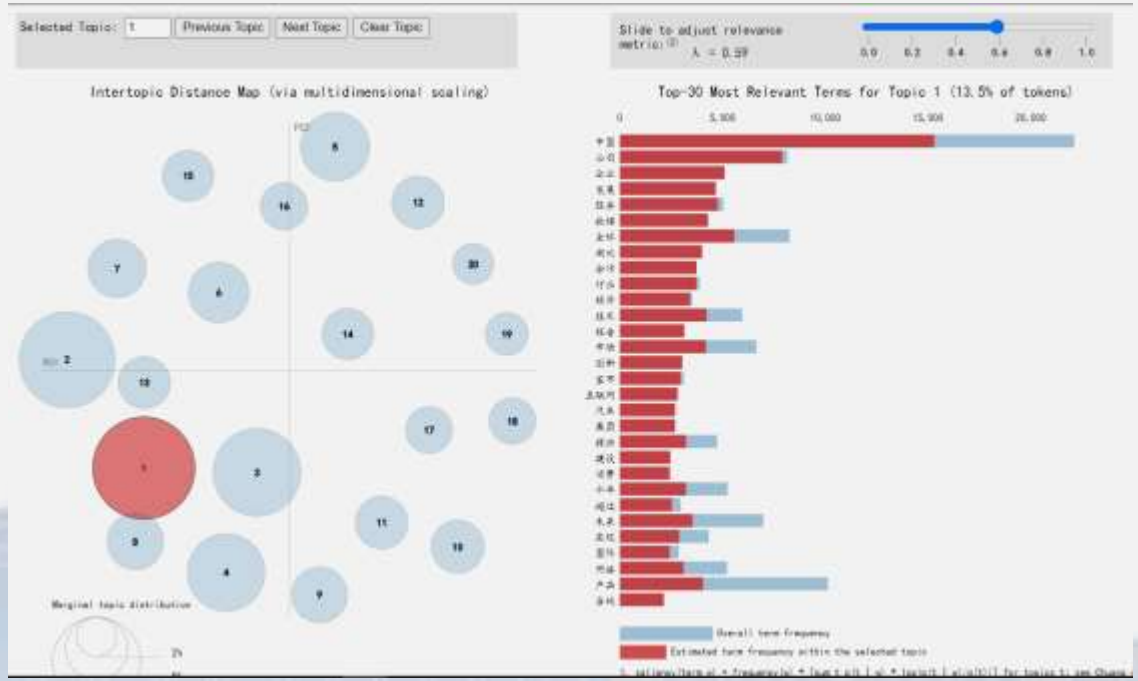
- **旭日图** (sunburst diagram)
  - 也称为**多层饼图**或**径向树图**
  - 通过一系列的圆环显示**层次结构**，再按不同类别的节点进行切割。每个圆环代表层次结构中的一个级别，中心圆表示根节点，层次结构从根节点往外推移
  - 之后圆环会按照其与原属切片的层次关系再被分割，分割角度可以是均等平分，或者与某个数值成比例
  - 可以用不同颜色突出显示层次分组或特定类别



文本可视化

- 文本数据的可视化可以帮助人们更直观地理解和分析文本内容
  - 词云（Word Cloud）： 词云是一种展示文本数据中出现频率的可视化方式，其中出现频率高的词汇以较大的字体显示，而频率低的词以较小的字体显示
  - 气泡图（Bubble Chart）： 在文本分析中，气泡图可以显示不同实体或主题的相关性和影响力，其中气泡的大小通常表示重要性或频率，而位置可以表示分类或关系





有效的数据图表

- 让数据脱颖而出
  - 填充数据区域（轴、范围）
  - 为不同的组使用视觉上不同的符号（形状、颜色）
  - 避免图表垃圾 (chart junk)、厚重的网格线
- 便于比较
  - 从视觉上强调重要的比较
  - 并排(side-by-side)比单独绘图更容易比较
  - “数据”与“标准”在水平线上更容易比较
- 效果排序
  - 信息展示通常要按照时间或某种特定顺序
  - 根据预知要观察的“效果”或“效应”对数据进行排序，以更方便地用于查找、比较、检测（模式、趋势、异常值）

效果排序——以相关性为例

- 过多的小数位数加重了认知负荷，造成杂乱感

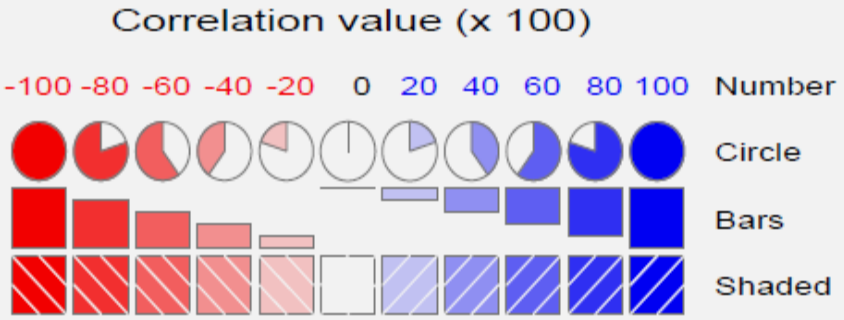
```
> cor(bb)
         Assists  Atbat   Errors    Hits     Homer  logSal Putouts    RBI   Runs  Walks   Years
Assists  1.0000 0.3421  0.70350 0.3040 -0.16160  0.0500 -0.0434 0.0629  0.179 0.1025 -0.0851
Atbat    0.3421 1.0000  0.32558 0.9640  0.55510  0.4149  0.3096 0.7960  0.900 0.6244  0.0127
Errors   0.7035 0.3256  1.00000 0.2799 -0.00974 -0.0208  0.0753 0.1502  0.193 0.0819 -0.1565
Hits     0.3040 0.9640  0.27988 1.0000  0.53063  0.4496  0.2997 0.7885  0.911 0.5873  0.0186
Homer   -0.1616 0.5551 -0.00974 0.5306  1.00000  0.3398  0.2509 0.8491  0.631 0.4405  0.1135
logSal   0.0500 0.4149 -0.02080 0.4496  0.33983  1.0000  0.2245 0.4441  0.426 0.4324  0.5374
Putouts -0.0434 0.3096  0.07531 0.2997  0.25093  0.2245  1.0000 0.3121  0.271 0.2809 -0.0200
RBI      0.0629 0.7960  0.15015 0.7885  0.84911  0.4441  0.3121 1.0000  0.779 0.5695  0.1297
Runs     0.1793 0.8998  0.19261 0.9106  0.63108  0.4256  0.2712 0.7787  1.000 0.6970 -0.0120
Walks    0.1025 0.6244  0.08194 0.5873  0.44045  0.4324  0.2809 0.5695  0.697 1.0000  0.1348
Years   -0.0851 0.0127 -0.15651 0.0186  0.11349  0.5374 -0.0200 0.1297 -0.012 0.1348  1.0000
```

- 通过四舍五入减少数字位数

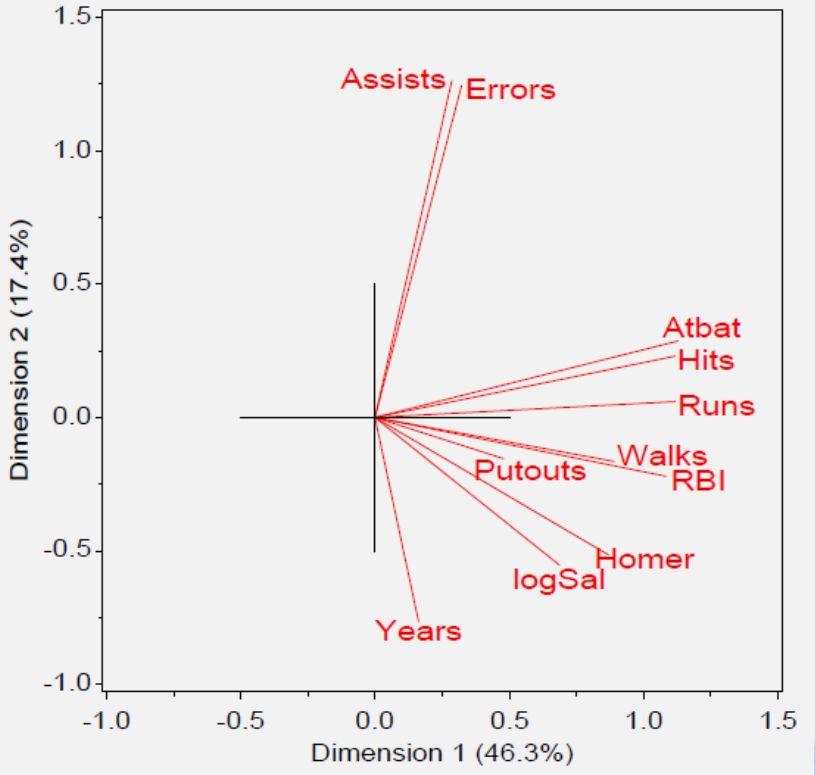
```
> round(100*cor(bb))
         Assists Atbat Errors Hits Homer logSal Putouts RBI Runs Walks Years
Assists      100    34     70   30   -16      5      -4   6   18    10    -9
Atbat         34   100     33   96    56     41      31  80   90    62     1
Errors        70    33    100   28    -1     -2       8  15   19     8   -16
Hits          30    96     28  100    53     45      30  79   91    59     2
Homer        -16    56     -1   53   100     34      25  85   63    44    11
logSal         5    41     -2   45    34    100      22  44   43    43    54
Putouts       -4    31      8   30    25     22     100  31   27    28    -2
RBI            6    80     15   79    85     44      31 100   78    57    13
Runs          18    90     19   91    63     43      27  78  100    70    -1
Walks         10    62      8   59    44     43      28  57   70   100    13
Years         -9     1    -16    2    11     54      -2  13   -1    13   100
```

效果排序——以相关性为例

- 渲染 (rendering)：对于不同的任务，相关值可以以不同的方式显示

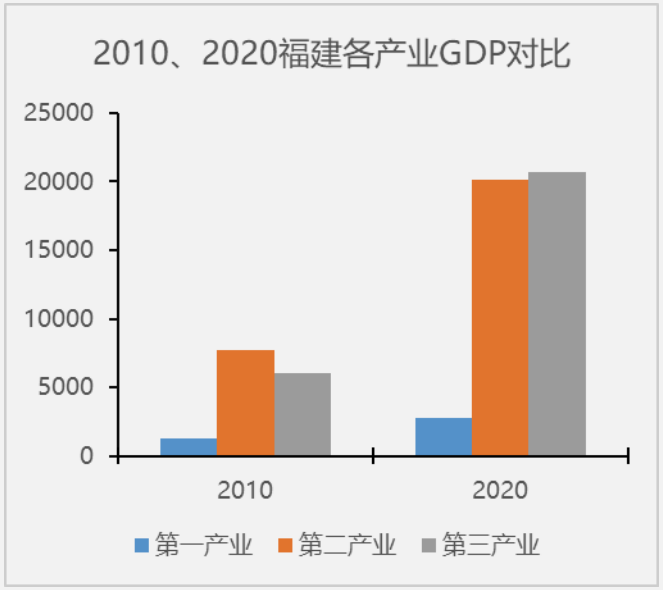


- 相关性排序：
  - 主成分分析(PCA)找到变量的加权和，以最大化方差
  - 向量之间的角度反映了相关性
  - 按角度顺序排列变量



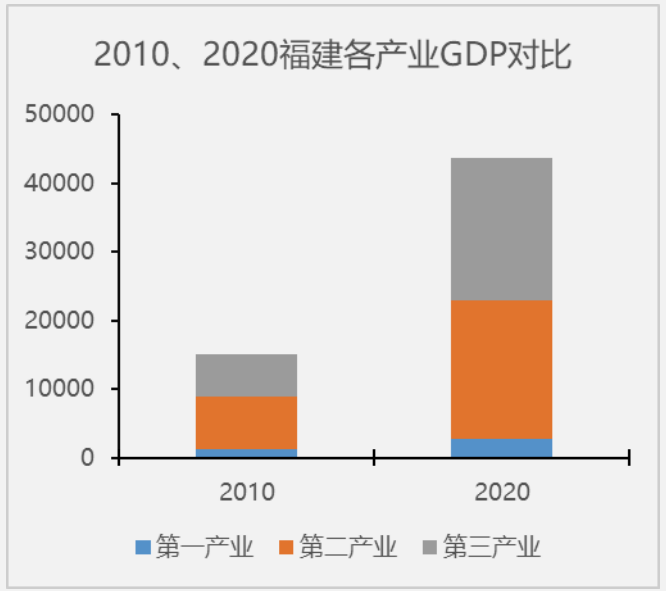
Friendly (2002), *Corrgrams: Exploratory displays for correlation matrices,* American Statistician.

有效的数据图表

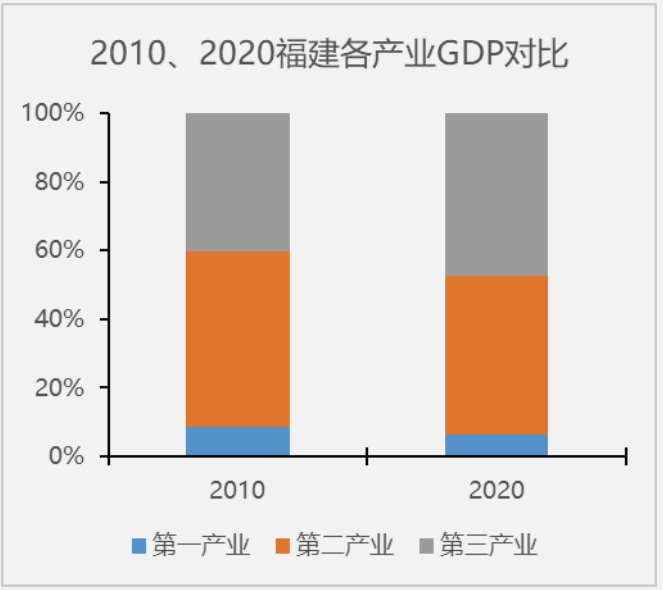


分组条形图

V.S.



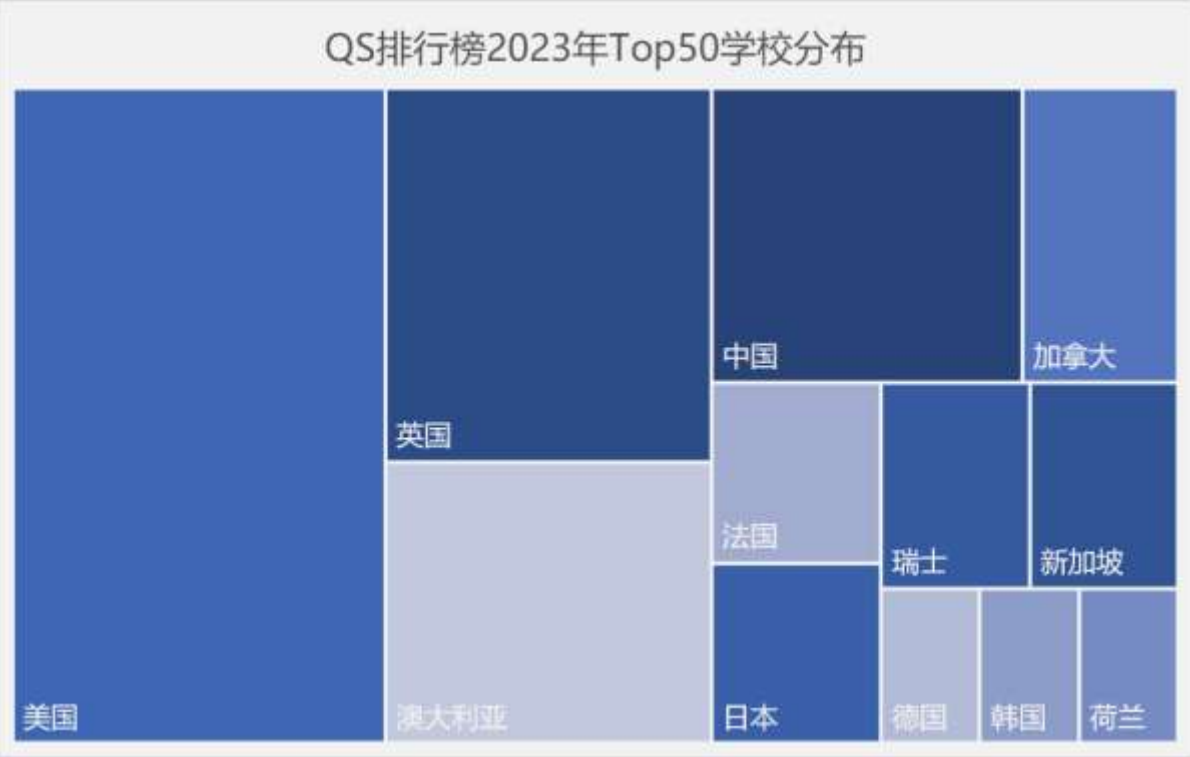
堆叠条形图（绝对值）



堆叠条形图（比例）

有效的数据图表

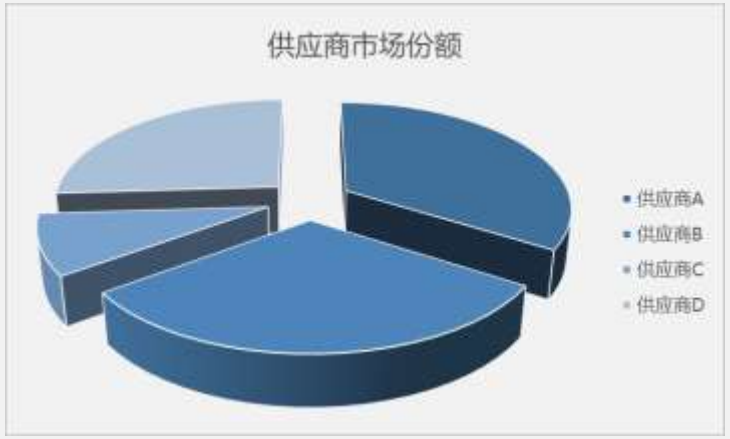
- **面积图**通过各个类别面积的大小来进行对比
  - 人们实际上很难通过肉眼来比较面积的大小
  - 除非数据相差极大，尽量避免使用面积图



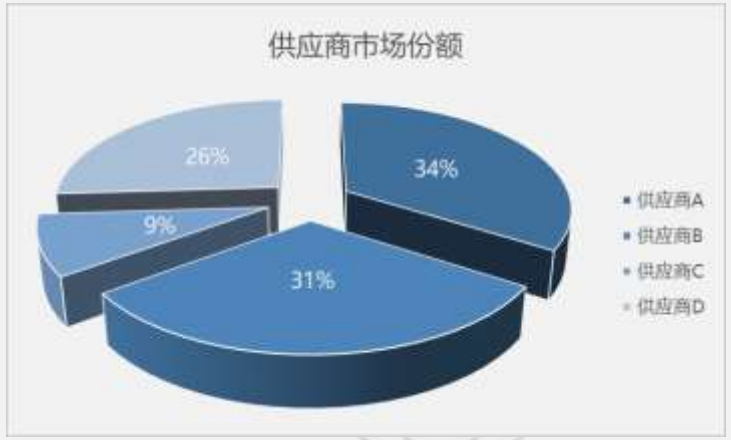
瑞士和法国在图中哪个面积更大？

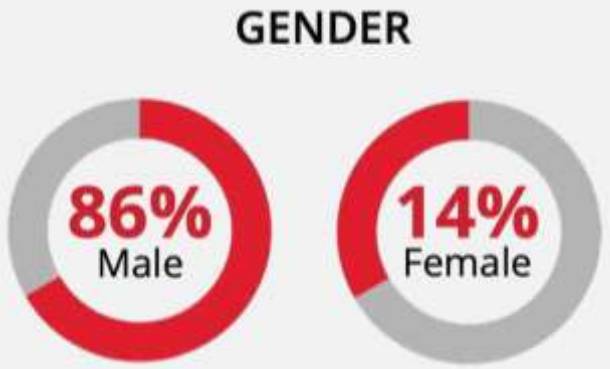
有效的数据图表

- **“邪恶的饼图”**(evil pie charts)
  - 劣质饼图随处可见
  - 饼图难以阅读，就像面积图一样很难比较大小
  - 饼图的功能完全可以由条形图来替代

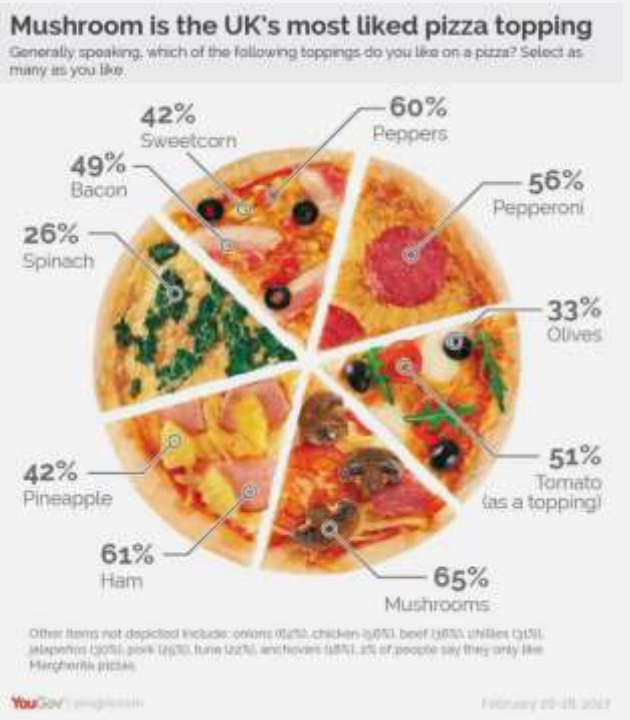


哪个供应商市场份额更大？
大概占比多少？





我应该相信哪个比例？

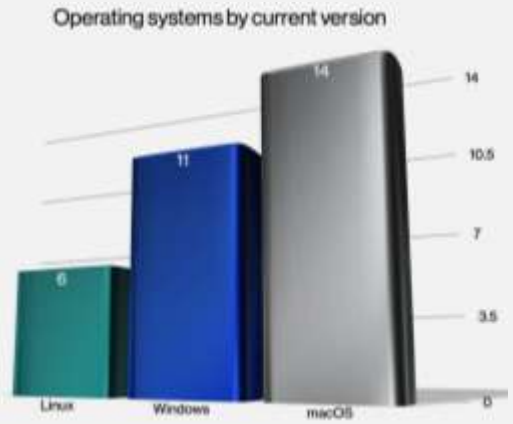


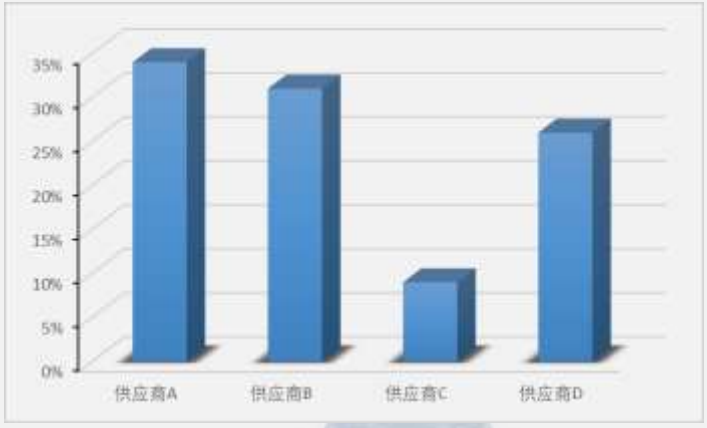
这个比例是什么含义？

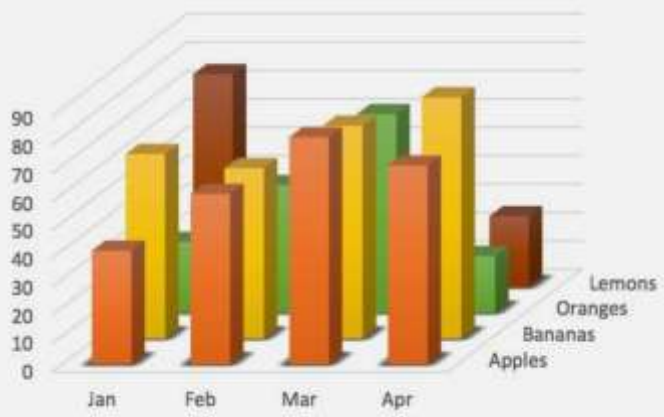
需要避开的陷阱

➢3D图形

- ➢3D图形的视角会造成视觉误导
- ➢除非是为了绘制三维空间，尽量避免使用3D图形
- ➢在图形中使用3D会引入边界、底座等不必要元素，并且让人无法判断数据到底是多少



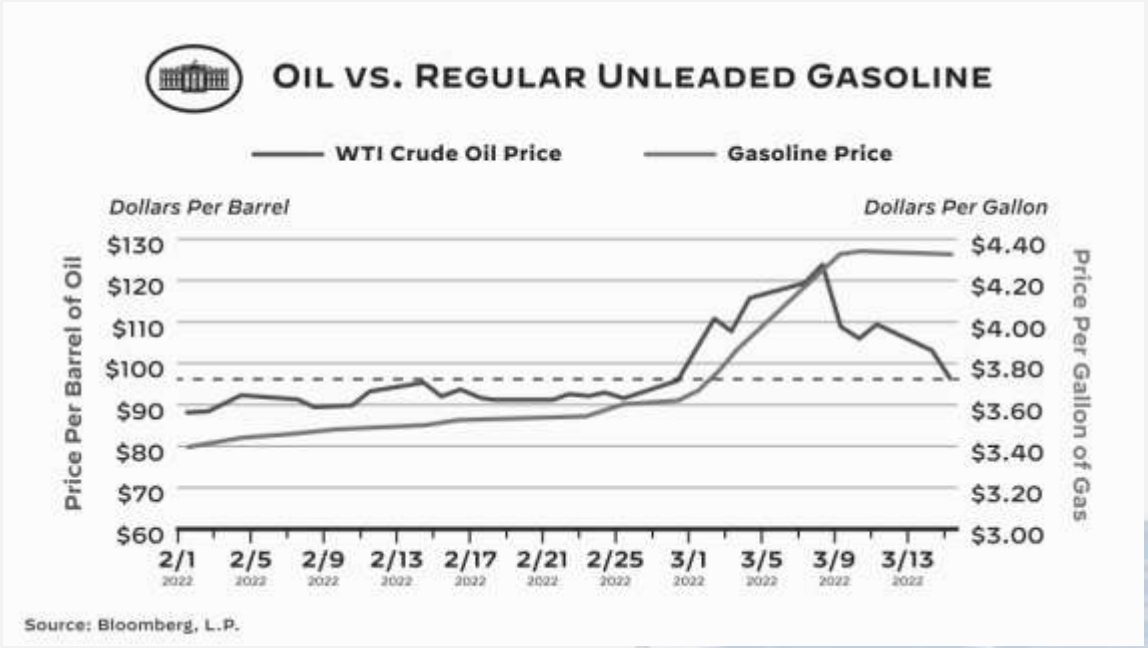




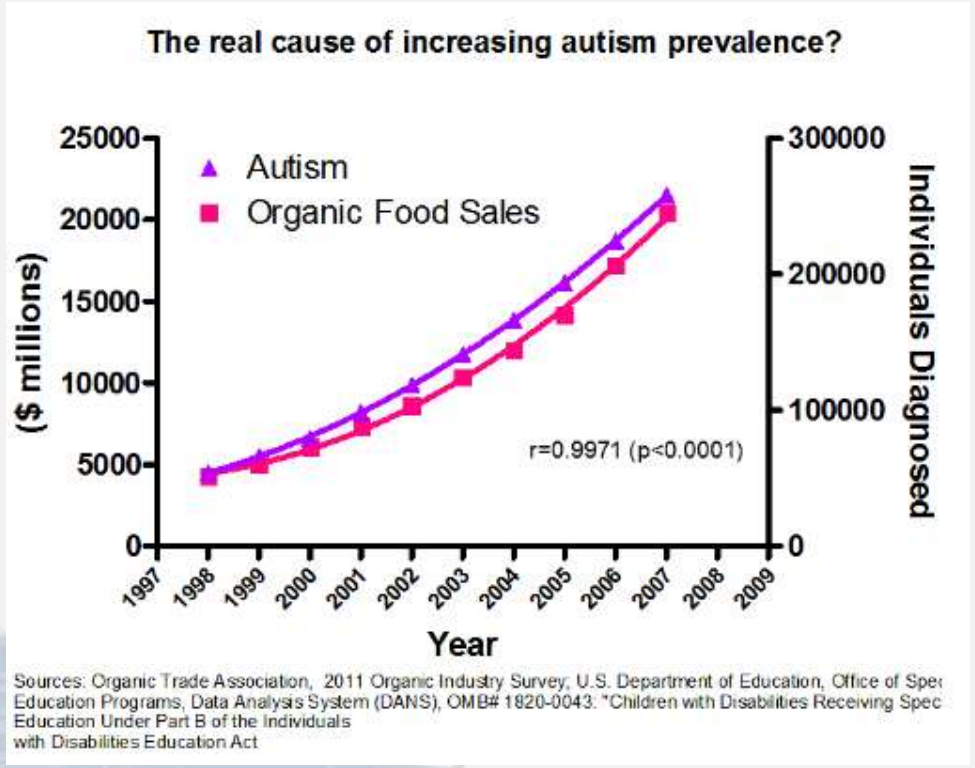
需要避开的陷阱

➢双y轴

- ➢双y轴会需要花费额外的时间精力去理解图形数据，甚至产生误导
- ➢使用双y轴可以控制两个轴的刻度，有意在图表上显示2个时间序列之间的某种相关性，可能会暗示不正确的因果关系



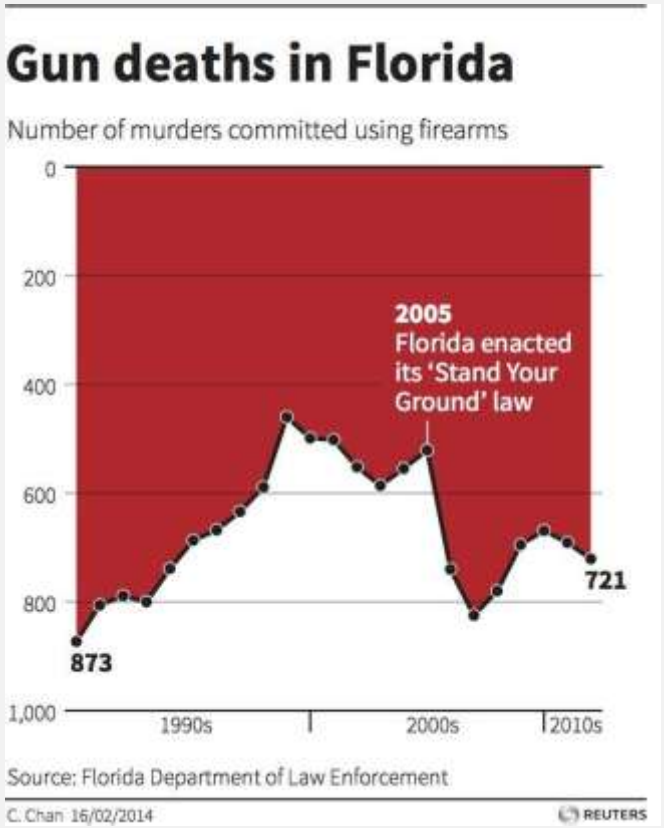
“我该看哪里？”

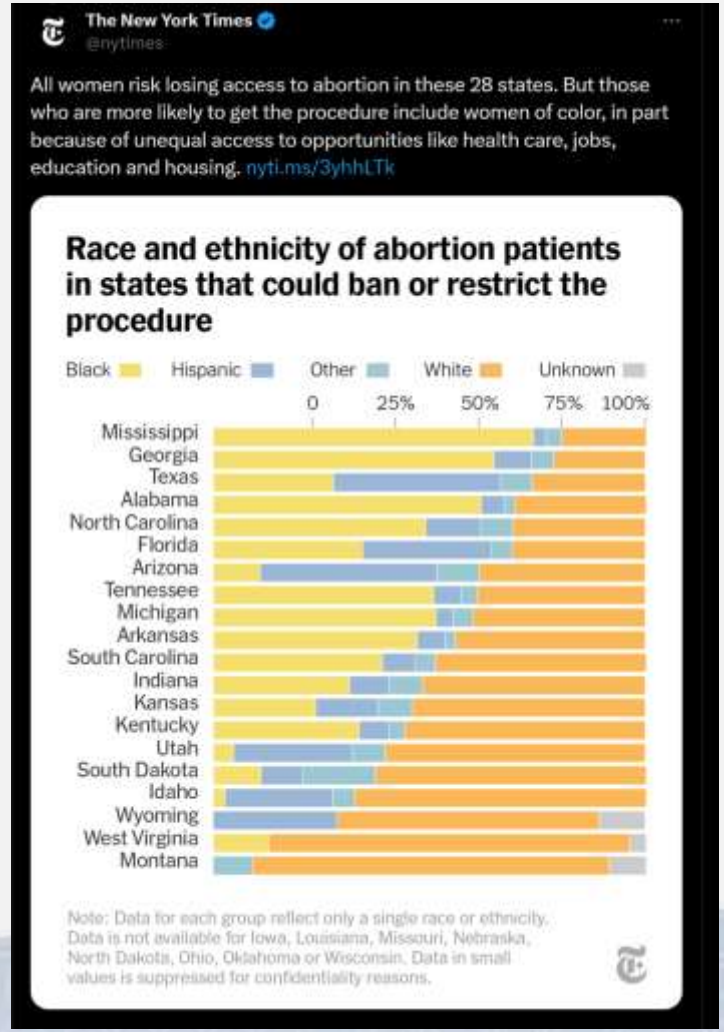


自闭症数量随着有机食品销量的增加而增加！——禁止有机食品

需要避开的陷阱

➢不规则刻度和未对齐的轴刻度

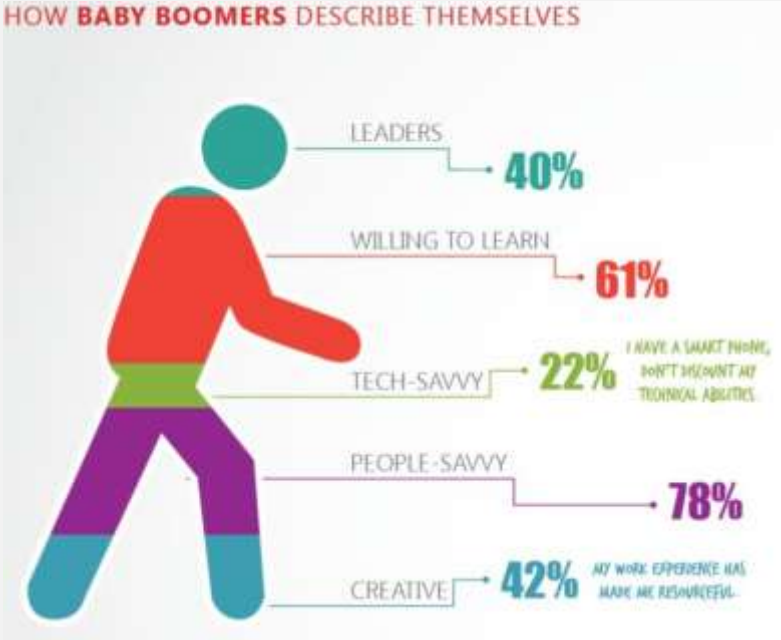




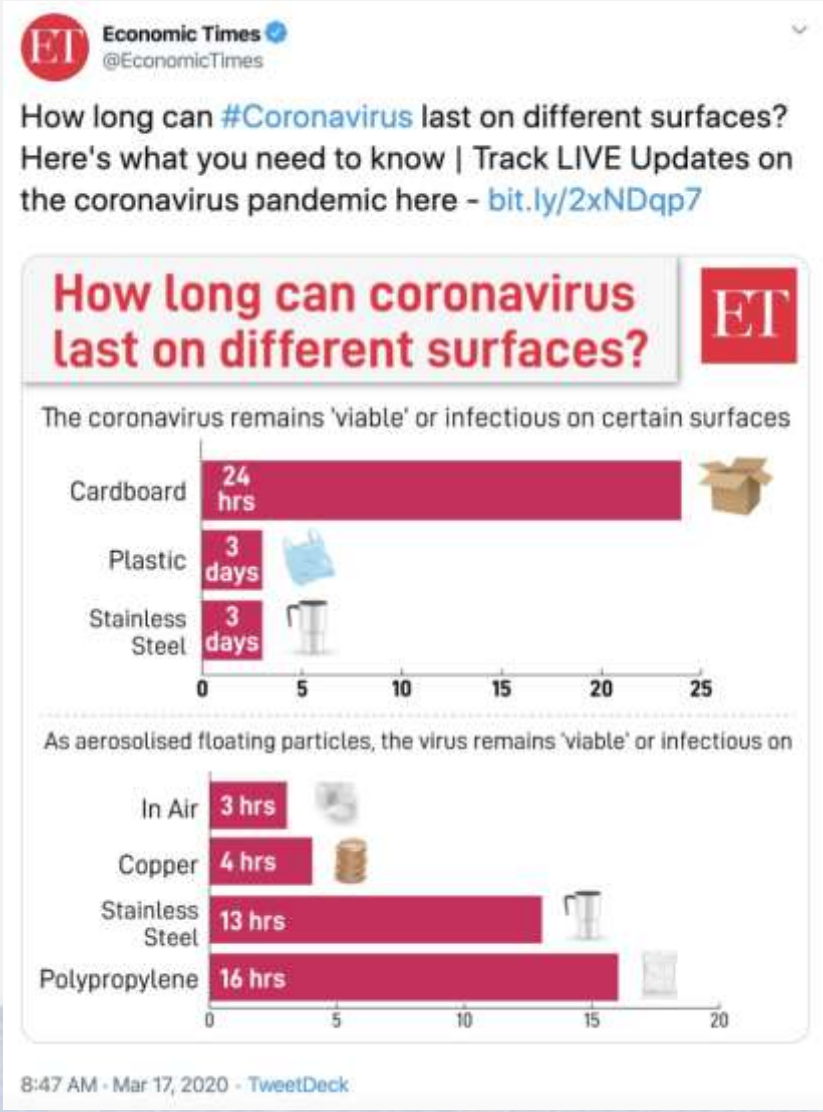


需要避开的陷阱

- 数据扭曲
  - 不合理的标记、轴长、比例会模糊和扭曲数据，造成误导

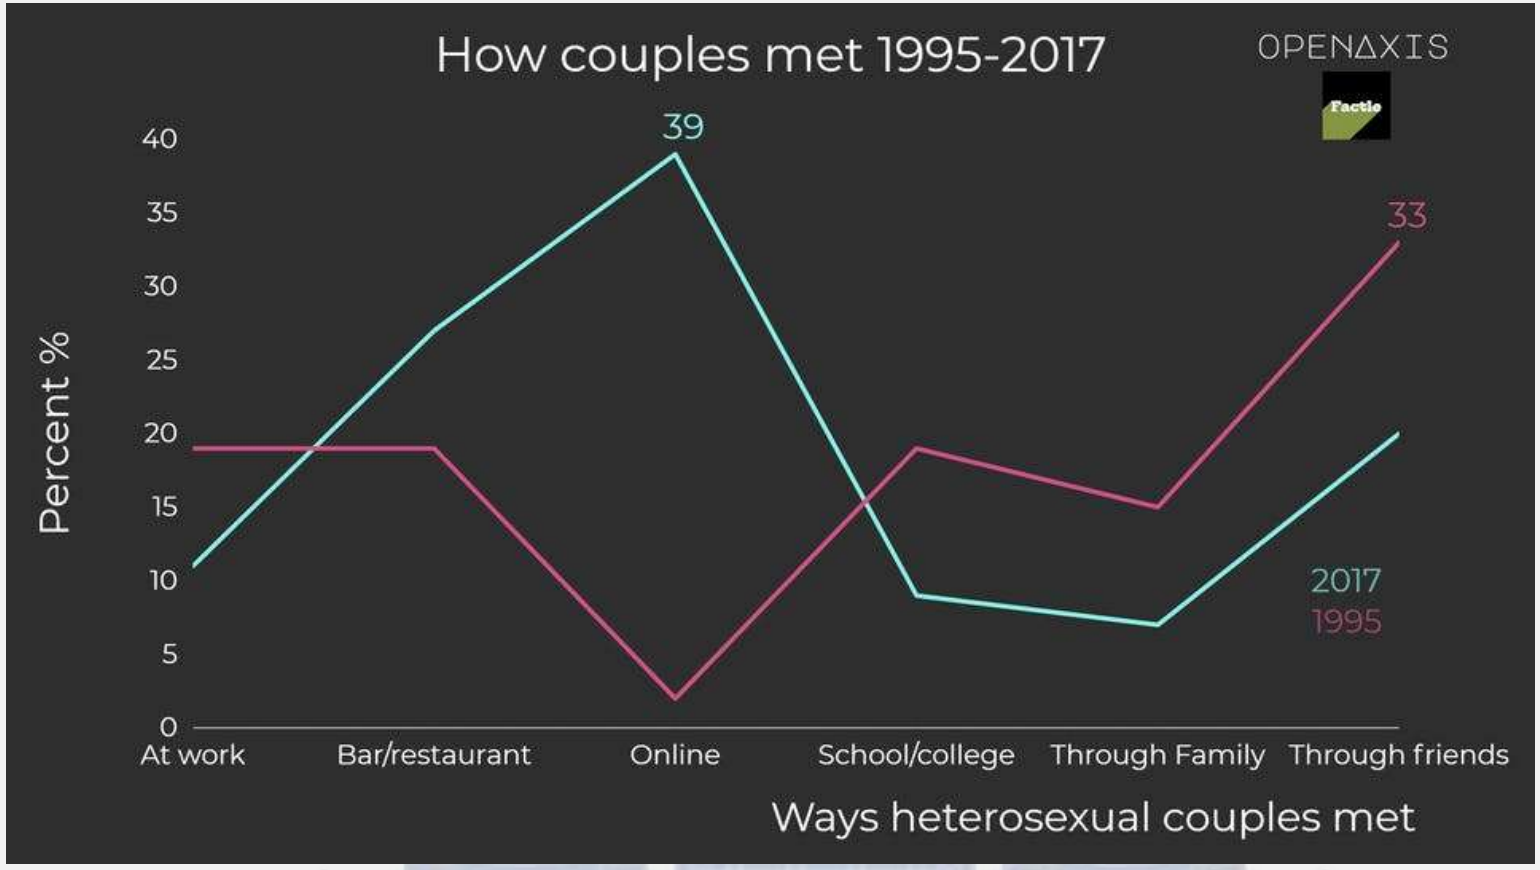






需要避开的陷阱

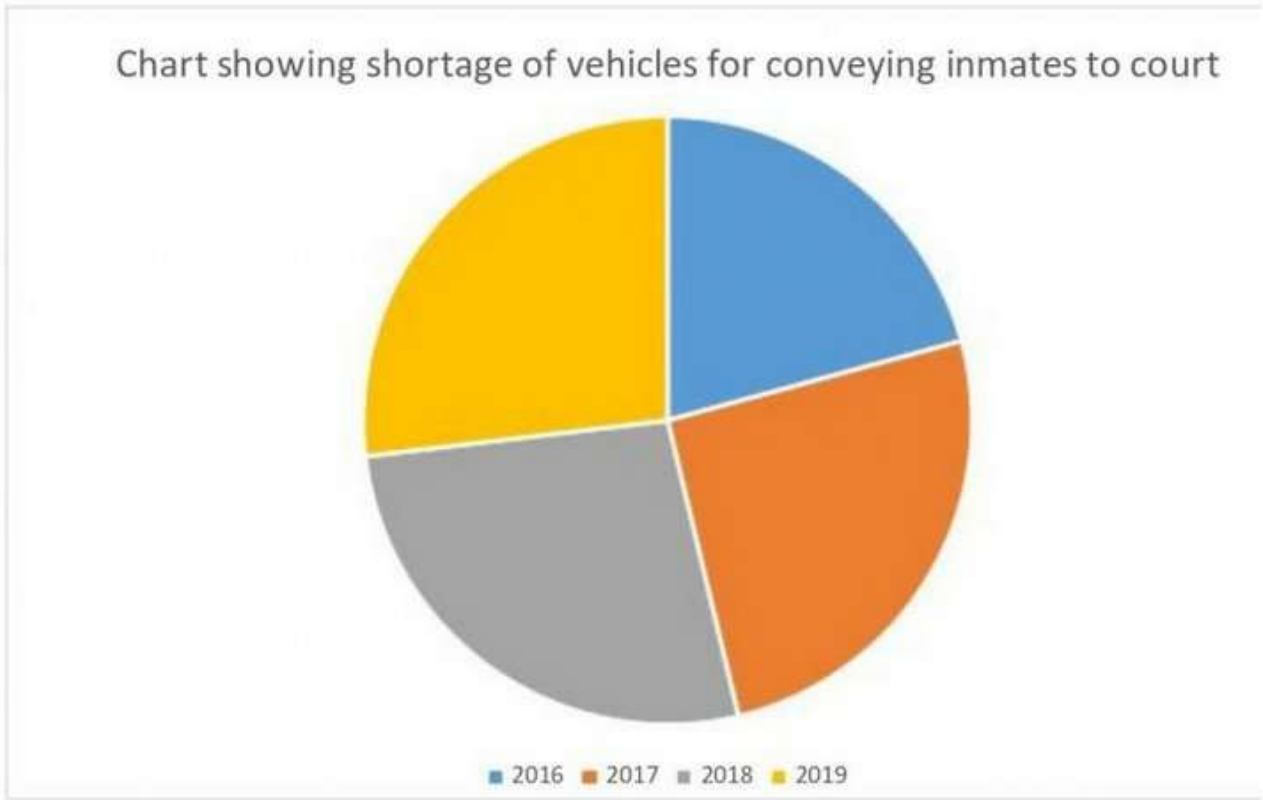
➢不合理的图表选择



类别数据以时间序列线图呈现

需要避开的陷阱

➢不合理的图表选择

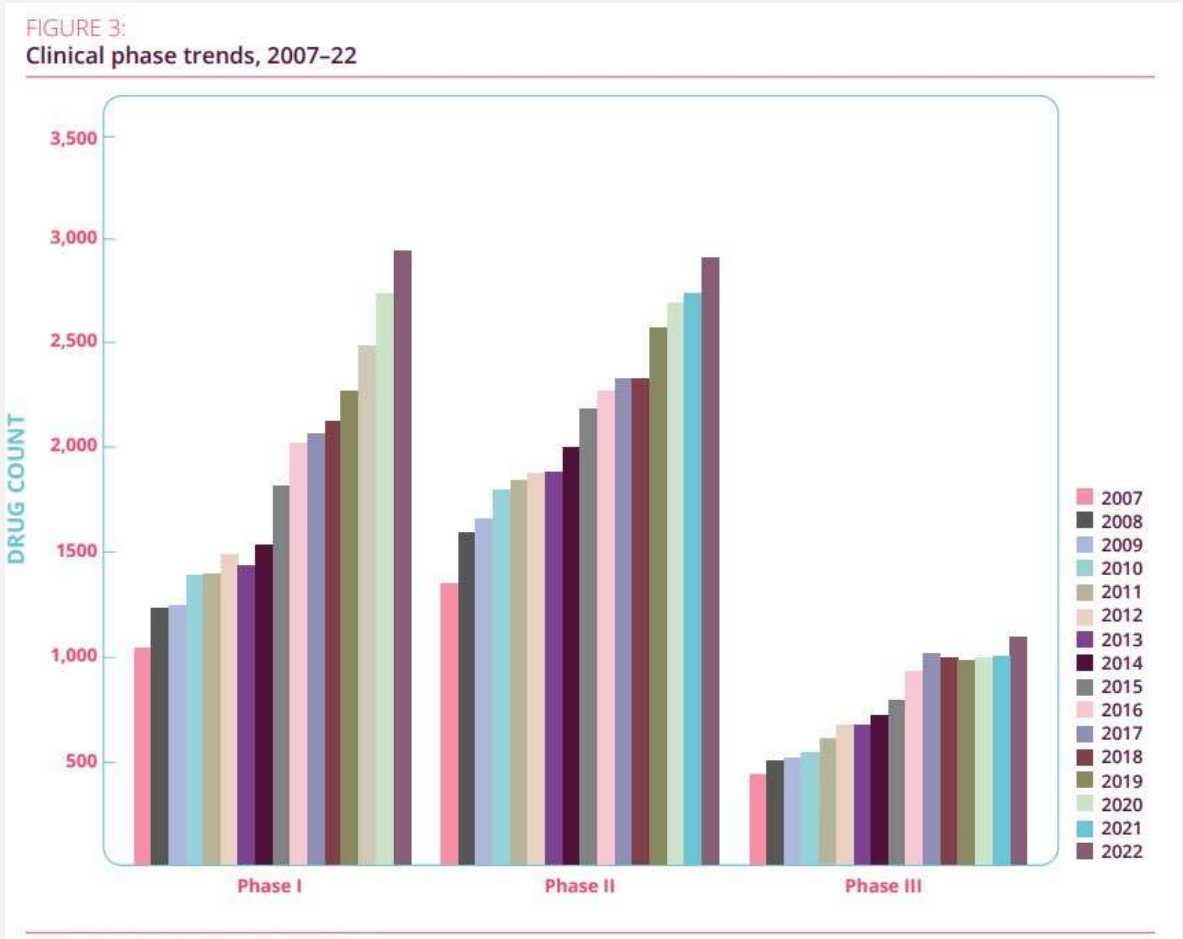


Before 2016, the Nigerian prisons said it had only two vehicles for conveying an average of 400 people to court, daily.

时间序列变化以饼图形式呈现

需要避开的陷阱

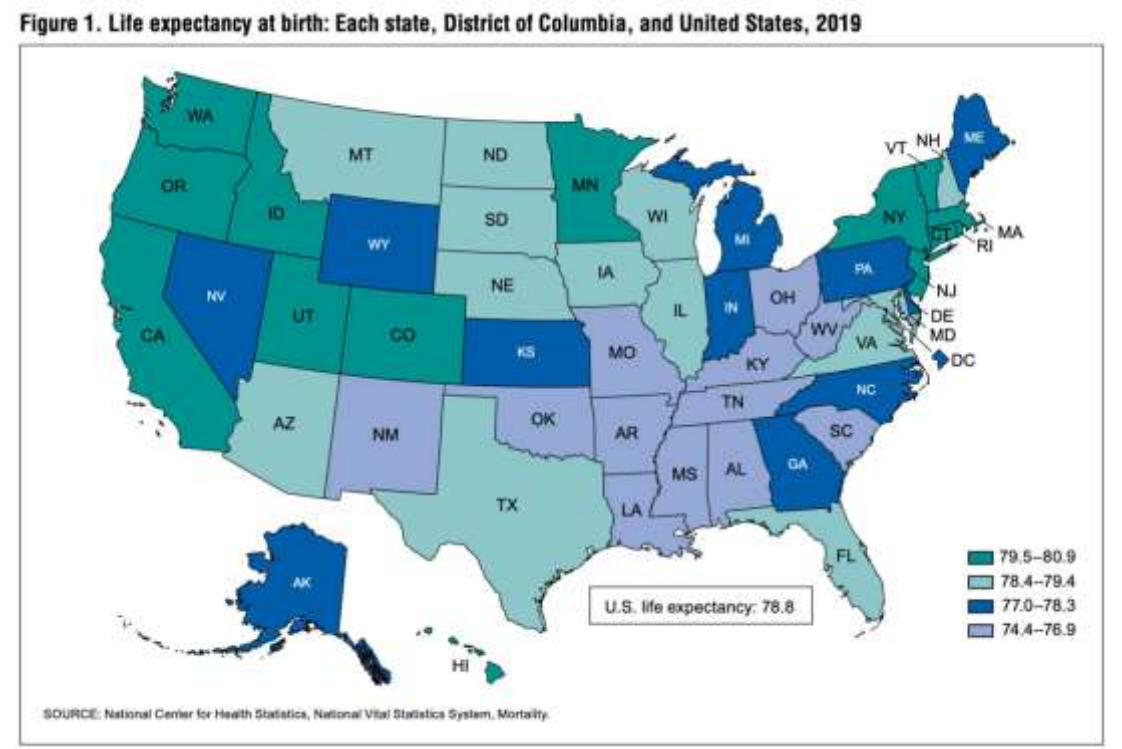
➢不合理的图表选择

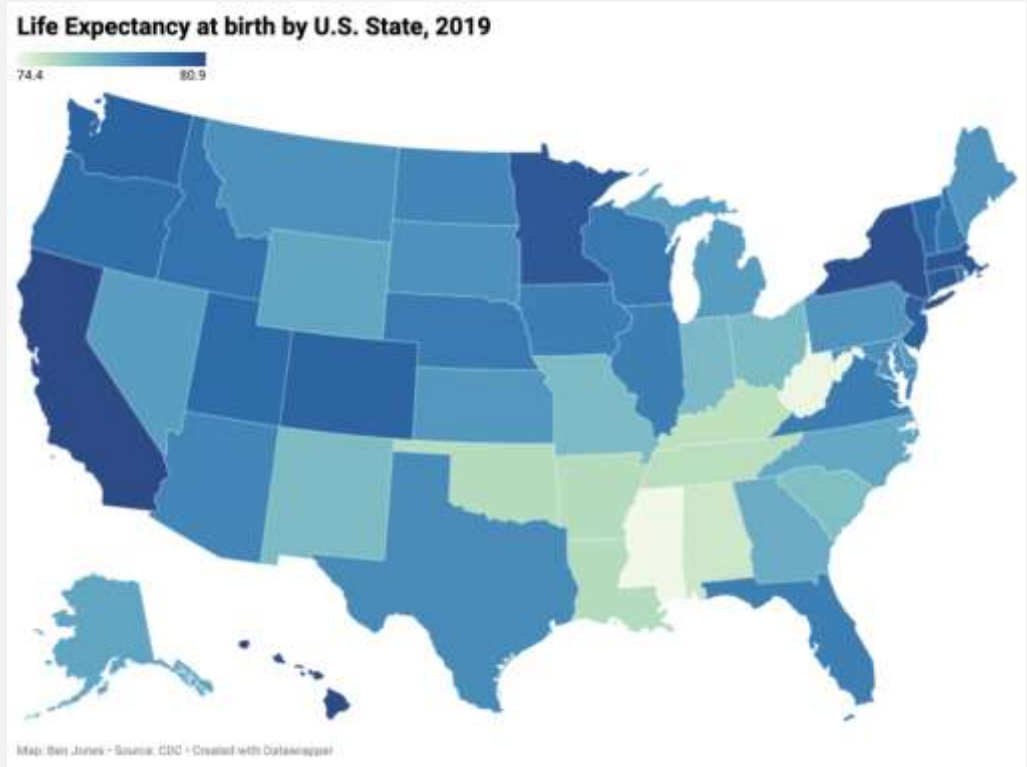


连续的时间序列变化以离散比较的形式呈现

需要避开的陷阱

➢颜色陷阱





颜色的选择并不能反映年龄区间的序数属性，无法通过颜色深浅分辨和比较不同洲的预期平均寿命

使用**顺序色图**(sequential colormap)来表示量级的递增

需要避开的陷阱

➢颜色陷阱





本章小结

- 可视化图表的类型
  - 基本统计图表
    - 线图、斜率图、螺旋图、平行坐标图、桑基图、条形图、直方图、密度图、QQ图、箱型图、小提琴图、热力图、散点图、气泡图
  - 专题地图
    - 地区分布图、等值线图
  - 网络和树形可视化
  - 文本可视化
- 可视化图表的使用误区

本章完

